

Politecnico Di Bari

Dipartimento di Ingegneria Elettrica e dell'Informazione

Corso di Laurea Triennale in
Ingegneria dei Sistemi Medicali

Tesi di Laurea in
Fondamenti di Automatica

L'Intelligenza Artificiale a Supporto della Diagnosi del Disturbo dello Spettro Autistico

Relatore:
Chiar.mo Prof. Michele Roccotelli

Correlatori:
Dott. Wasim Ali

Laureando:
Aaron Galetta

ANNO ACCADEMICO 2025-2026

Politecnico di Bari

LIBERATORIA ALLA CONSULTAZIONE DELLA TESI DI LAUREA DI CUI ALL'ART.4 DEL REGOLAMENTO DI ATENEO PER LA CONSULTAZIONE DELLE TESI DI LAUREA (D.R. n. 479 del 14/11/2016).

Il sottoscritto_____matricola_____

Corso di Laurea

_____

autore della presente tesi di Laurea dal titolo

_____

_____

Parola chiave_____

Abstract_____

_____

_____

_____

□ Autorizza

□ Non autorizza

la consultazione della presente tesi, fatto divieto a chiunque di riprodurre in tutto o in parte quanto in essa contenuto.

Bari,

Firma_____

La/il sottoscritta/o,

Cognome: _____

Nome: _____

Matricola: _____

Data Seduta Laurea: ____/____/_____.

dichiara

che la tesi cartacea consegnata in data odierna è conforme a quella caricata su esse3, quindi, approvata dal Relatore Prof. _____

(in stampatello)

Bari, ____/____/_____

Firma

_____

Inserire qui l'eventuale dedica.
Questo è un esempio di capoverso che serve per mostrare
le caratteristiche dello stile "Dedica".
Usare l'interruzione di riga forzata (SHIFT+INVIO)
per mantenere unite le righe.

Indice

Elenco delle Tabelle **1**

Elenco delle Figure **2**

Introduzione e Scopo della Tesi **4**

1 Disturbo dello Spettro Autistico – caratteristiche cliniche, epidemiologia e diagnosi **7**

1.1 Definizione e caratteristiche cliniche . . . 7
1.2 Epidemiologia . . . 8
1.3 Classificazione . . . 9
1.4 Fattori di rischio . . . 10
1.5 Diagnosi classica e relativi limiti . . . 12

2 Intelligenza Artificiale: Machine Learning e Deep Learning **14**

2.1 Fondamenti di Machine Learning . . . 14
2.2 Deep Learning e applicazioni in ambito biomedico . . . 15
2.3 Dataset . . . 17
2.3.1 Training set . . . 17
2.3.2 Validation set . . . 18
2.3.3 Test Set . . . 18
2.4 Metriche di valutazione . . . 19
2.4.1 Accuracy . . . 20
2.4.2 Precision . . . 20
2.4.3 Sensitivity . . . 21
2.4.4 F1-score . . . 21
2.4.5 AUC . . . 21
2.5 Data Preprocessing . . . 23
2.5.1 Gestione dei valori mancanti . . . 23
2.5.2 Rilevamento e gestione degli outlier . . . 25
2.5.3 Gestione dei duplicati . . . 26
2.5.4 Normalizzazione . . . 27
2.5.5 Standardizzazione . . . 28
2.5.6 Encoding delle variabili categoriche . . . 29
2.5.7 Bilanciamento delle classi . . . 29

2.6 Feature selection 30
2.6.1 Filter methods 31
2.6.2 Wrapper methods 31
2.6.3 Embedded methods 32

3 Modello di Deep Learning per la predizione del Disturbo dello Spettro Autistico 35
3.1 Descrizione del dataset 35
3.2 Preprocessing per il modello LSTM 36
3.3 Creazione delle sequenze temporali 37
3.4 Architettura del modello 38
3.4.1 Scelta della BiLSTM 38
3.4.2 Descrizione dell'architettura 39
3.5 Tecniche di ottimizzazione e regolarizzazione 40
3.6 Training del modello 41
3.7 Valutazione delle prestazioni 42
3.7.1 Discussione dei risultati 45
3.7.2 Confronto con il modello iniziale 45
3.8 Considerazioni finali sul modello 47
3.8.1 Punti di forza 47
3.8.2 Limiti 47
3.8.3 Spunti per lavori futuri 48

Conclusioni 50

Bibliografia e Sitografia 53

Ringraziamenti 58

Elenco delle Tabelle

3.1 Classification report del modello LSTM bidirezionale. 42
3.2 Classification report del modello MLP di partenza. 46
3.3 Confronto tra modello iniziale (MLP) e modello finale (BiLSTM). . 46

Elenco delle Figure

1.1 Elaborazione grafica dei dati sui Disturbi dello Spettro Autistico forniti dalla rete di monitoraggio dell'autismo e dei disturbi dello sviluppo (ADDM) del CDC. 8

2.1 Esempio di matrice di confusione con le quattro possibili categorie di predizione. 20
2.2 Esempio di curve ROC. La curva mostra la relazione tra il tasso di veri positivi (TPR) e il tasso di falsi positivi (FPR) al variare della soglia di classificazione. Si osservano tre modelli con prestazioni differenti: un modello buono (AUC ≈ 0.85), un modello medio (AUC $= 0.5$, classificazione casuale) e un modello scarso (AUC ≈ 0.3). . . 22
2.3 Esempio di distribuzione di dati con la presenza di *outlier* (in rosso), che si discostano sensibilmente dal gruppo principale di osservazioni (in giallo). 25
2.4 Esempio di normalizzazione con Min-Max Scaling: a sinistra i dati originali, a destra i dati trasformati nell'intervallo [0,1]. 27
2.5 Esempio di standardizzazione tramite z-score: a sinistra i dati originali con media diversa da zero, a destra i dati trasformati con media pari a 0 e deviazione standard pari a 1. 28

3.1 Accuratezza complessiva del modello. 43
3.2 Metriche per classe (ASD vs Neurotipici): precision, recall e F1-score. 43
3.3 Matrice di confusione del modello (ASD vs Neurotipici). 44
3.4 Curva ROC del modello. L'area sotto la curva (AUC) è pari a 0,96, indicando un'ottima capacità discriminante tra soggetti ASD e neurotipici. La vicinanza della curva all'angolo in alto a sinistra riflette alta sensibilità e specificità, con riduzione di falsi positivi e falsi negativi. 44

Introduzione e Scopo della Tesi

Il Disturbo dello Spettro Autistico (ASD) è una condizione che coinvolge lo sviluppo neurologico e si manifesta con un ampio spettro di sintomi. La sintomatologia comprende problemi che spaziano dalla comunicazione e all'interazione sociale, dalla ripetitività nei comportamenti a una restrizione degli interessi. Considerando la diversa intensità mediante cui tali aspetti si presentano, è possibile riscontrare soggetti in grado di svolgere attività giornaliere in autonomia e soggetti la cui quotidianità deve essere supervisionata costantemente.

Il Disturbo dello Spettro Autistico è spesso accompagnato da altre complicazioni cliniche come l'epilessia, i disturbi da deficit di attenzione o l'iperattività, che richiedono interventi terapeutici specifici [1].

Le eziologie dell'autismo sono complesse e multifattoriali. Studi su gemelli e le loro famiglie indicano che fino al 90% del rischio di nascere l'ASD può essere attribuibile alla genetica [2]. Una relativa importanza la ricoprono anche i fattori ambientali durante la gravidanza, che possono portare allo sviluppo del disturbo nel nascituro. Tra le possibili cause scatenanti si annoverano l'esposizione a tossine e diverse tipologie di infiammazione materna, ovvero può esserci una correlazione tra l'attivazione del sistema immunitario della madre durante la gravidanza e l'insorgenza del Disturbo dello Spettro Autistico [3].

Una meta-analisi dimostra che in tutto il mondo circa un bambino su cento (l'1% del totale) ha disturbi dello spettro autistico. Raggiungere una stima definitiva, tuttavia, è ancora complicato, giacché i criteri diagnostici differiscono nei vari Paesi e anche le caratteristiche socio-demografiche di ogni popolazione hanno un'influenza sulla rilevazione dei casi [4].

Secondo i dati ufficiali del Ministero della Salute italiano, 13,4 bambini ogni mille, nella fascia di età compresa tra i 7 e i 9 anni, risultano diagnosticati con ASD. Il rapporto maschi-femmine è di circa 4,4 : 1 [5].

Lo studio sviluppato per questa tesi si è avvalso di un dataset esistente di 59 bambini (29 con diagnosi di ASD e 30 a sviluppo tipico), di età compresa tra i 2 e i 13 anni, ottenuto grazie a sessioni di eye–tracking. Al fine di ottenere risultati in ambito diagnostico è stato realizzato un codice che converte le traiettorie oculari in serie temporali e le alimenta attraverso una rete neurale ricorrente LSTM bidirezionale, in grado di riconoscere le dinamiche sequenziali all'interno dei movimenti oculari. I dati sono stati suddivisi in un set di training e in uno di validazione.

Le prestazioni dei modelli sono state poi valutate utilizzando parametri quali accuratezza, sensibilità e area che insiste sotto la curva ROC. L'obiettivo finale

è quello di mostrare come, grazie alla sinergia tra tecniche di Deep Learning e analisi dei percorsi visivi, si può offrire ai medici clinici uno strumento in più per individuare precocemente anche i segni più sottili di autismo.

—

Capitolo 1

Disturbo dello Spettro Autistico – caratteristiche cliniche, epidemiologia e diagnosi

1.1 Definizione e caratteristiche cliniche

Il Disturbo dello Spettro Autistico (ASD) appartiene ai disturbi del neurosviluppo e si manifesta con modalità molto eterogenee [6, 7, 8]. Può influenzare in modo significativo le aree della socializzazione, della comunicazione e del comportamento quotidiano.

I termini "spettro" o "continuum di disturbi" derivano dal fatto che il quadro clinico non è né uniforme né delimitato, poiché la condizione può interessare diverse aree del funzionamento neurologico e comportamentale. Ogni individuo può quindi presentare sintomi e livelli di gravità differenti [9].

La sintomatologia è generalmente suddivisibile in tre categorie principali:

- **Difficoltà nella comunicazione sociale**: si manifestano problemi nella comprensione e nell'utilizzo del linguaggio verbale e non verbale, criticità nell'avviare e mantenere conversazioni o interazioni sociali e una ridotta capacità di interpretare le emozioni proprie o altrui, decifrare le intenzioni e i segnali sociali provenienti dall'esterno.

- **Comportamenti e interessi ripetitivi o ristretti**: vengono sviluppati interessi circoscritti a specifici argomenti. Inoltre si consolida una ripetitività nei movimenti, fino a sostanziarsi in veri e propri rituali (come, ad esempio, battere le mani o dondolarsi). Le persone con un disturbo dello spettro tendono anche ad aderire rigidamente alla routine e ad opporre resistenza ai cambiamenti.

- **Variabilità funzionale e adattiva**: alcuni individui riescono a vivere in autonomia, mentre altri necessitano di supporto costante nelle attività quotidiane.

1.2 Epidemiologia

Il disturbo dello spettro autistico è una condizione relativamente comune, la cui prevalenza varia in base ai criteri diagnostici e alle caratteristiche socio-demografiche della popolazione studiata [8].

Negli Stati Uniti vengono condotte da anni ricerche accurate sul numero di soggetti affetti, mentre in Italia i dati pubblici disponibili sono ancora limitati. Secondo il ministero della Salute, nel nostro Paese la prevalenza è di circa **13,4 bambini ogni mille**, nella fascia di età compresa tra i 7 e i 9 anni [10].

Il *Centers for Disease Control and Prevention* (CDC) di Atlanta conduce da anni una ricerca epidemiologica in 16 stati USA, nello specifico sui bambini di 8 anni. Nel 2022, la prevalenza dell'autismo ha raggiunto **32,2 casi ogni mille bambini**, ossia circa un bambino statunitense su 31 [11].

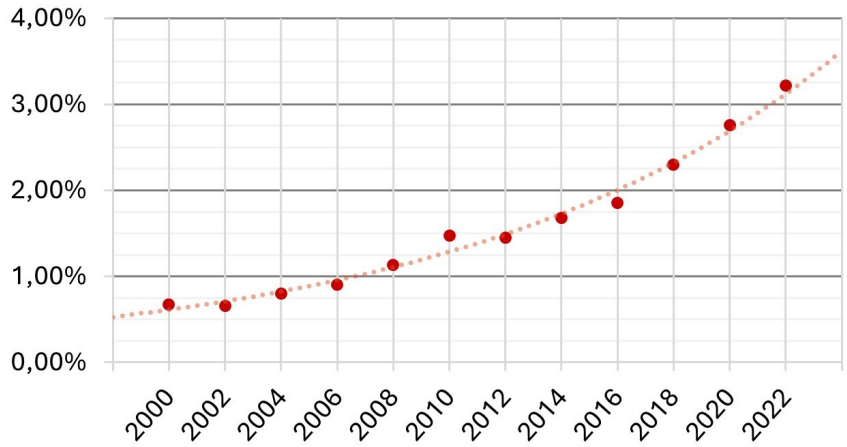


Figura 1.1: Elaborazione grafica dei dati sui Disturbi dello Spettro Autistico forniti dalla rete di monitoraggio dell'autismo e dei disturbi dello sviluppo (ADDM) del CDC.

Fonte: SapereAudete, `https://commons.wikimedia.org/wiki/File:Autism_in_the_US.jpg`

Un aspetto importante riguarda la distribuzione per genere. Per decenni si è parlato di un rapporto di circa **4 maschi per ogni femmina**, ma ricerche più recenti hanno dimostrato che questa stima è probabilmente sovrastimata a causa di bias diagnostici [12].

Se si utilizzano criteri più attenti al profilo femminile, il rapporto si riduce infatti a **3:1**, e in alcuni casi addirittura a **2:1**. Le ragazze con disturbi nello spettro spesso mostrano migliori abilità linguistiche e interessi più affini al resto della popolazione, il che può mascherare la condizione. Altresì, in molti casi, sviluppano strategie di adattamento sociale che rendono meno evidenti le difficoltà, ritardando così la diagnosi.

La disparità di genere riflette dunque in gran parte un problema di riconoscimento clinico e sottolinea la necessità di strumenti diagnostici più sensibili e accurati.

—

1.3 Classificazione

La classificazione del Disturbo dello Spettro Autistico ha subito notevoli cambiamenti negli ultimi decenni. Comprendere i diversi livelli di disturbo è di fondamentale importanza per definire il tipo di supporto, pianificare interventi educativi e terapeutici e offrire alle famiglie un quadro clinico esatto del bambino, ragazzo o adulto coinvolto.

Le prime descrizioni dell'autismo risalgono a metà del Novecento, grazie a Leo Kanner e Hans Asperger. I loro studi rappresentarono una svolta nella storia dell'autismo poiché, fino ad allora, il disturbo non era considerato una condizione clinica ben definita.

In particolare, Leo Kanner introdusse il termine "autismo infantile precoce" facendo riferimento a bambini che mostravano isolamento sociale, interessi ristretti e rigidità comportamentale [13].

D'altra parte, Asperger descrisse una condizione in cui, pur in presenza di difficoltà, il linguaggio e le capacità cognitive venivano relativamente conservate. Questa definizione fu poi ripresa anni dopo e venne associata al termine "Sindrome di Asperger".

Inizialmente, il Disturbo dello Spettro Autistico veniva facilmente confuso con altre condizioni come la schizofrenia infantile. A partire dagli anni '80, grazie alla pubblicazione del DSM-III, l'autismo fu riconosciuto ufficialmente come un disturbo del neurosviluppo.

Con l'avvento del DSM-IV e la successiva versione DSM-IV-TR, l'autismo venne dichiarato un Disturbo Pervasivo dello Sviluppo, insieme ad altre condizioni come la sopra citata Sindrome di Asperger, il Disturbo Disintegrativo della Fanciullezza e il Disturbo Pervasivo dello Sviluppo Non Altrimenti Specificato (PDD-NOS). Tuttavia, questa suddivisione si rivelò problematica, poiché le diverse categorie si sovrapponevano frequentemente e generavano confusione.

La svolta decisiva si ebbe con il DSM-V, aggiornato nel DSM-V-TR, che portò alla coniazione del termine Disturbo dello Spettro Autistico (ASD). Questa nuova definizione riflette l'idea che l'autismo non sia una condizione unica e uniforme, piuttosto uno spettro di manifestazioni cliniche che possono variare da individuo a individuo per gravità e intensità del disturbo [14].

Nel linguaggio comune si può parlare di autismo ad alto funzionamento, autismo non verbale e spettro autistico lieve. Sebbene non rappresentino categorie ufficiali, queste locuzioni descrivono differenze in termini di intensità dei sintomi, capacità di comunicazione e grado di autonomia.

Il livello di gravità di un paziente viene valutato, generalmente, da un neuropsichiatra per mezzo di una diagnosi che si basa su due principali domini:

1. Comunicazione e interazione sociale;

2. Interessi limitati e comportamenti ripetitivi.

Il DSM-V-TR ha introdotto inoltre una valutazione dimensionale della gravità, basata sul grado di supporto richiesto. Sono previsti tre livelli, che descrivono la compromissione funzionale e la necessità di aiuto nella vita quotidiana:

- **Livello 1 – Richiede supporto**: il più lieve, caratterizzato da difficoltà clinicamente significative ma che non impediscono del tutto una vita autonoma. È spesso associato a deficit nella comunicazione sociale, ridotta flessibilità comportamentale e ipersensibilità sensoriale. Con interventi psicoeducativi adeguati, le persone con autismo di livello 1 possono raggiungere un buon grado di indipendenza.

- **Livello 2 – Richiede supporto sostanziale**: i sintomi sono più marcati e interferiscono in modo significativo con l'autonomia. Le difficoltà risultano evidenti anche in presenza di supporto esterno. Le persone con autismo di livello 2 necessitano di sostegno costante nelle attività quotidiane.

- **Livello 3 – Richiede supporto molto sostanziale**: il più grave, caratterizzato da difficoltà profonde nella comunicazione sociale e da limitazioni comportamentali molto evidenti. Il linguaggio può essere fortemente compromesso o assente, mentre rigidità e stereotipie risultano marcate. Le persone con autismo di livello 3 necessitano di supporto continuativo e intensivo in tutti gli ambiti della vita quotidiana.

Parallelamente, anche l'Organizzazione Mondiale della Sanità ha introdotto la propria classificazione con l'ICD-11. Questa riconosce il Disturbo dello Spettro Autistico come un'unica condizione e pone l'attenzione su due ambiti principali:

1. Presenza o assenza di disabilità intellettiva;

2. Grado di compromissione del linguaggio funzionale.

Si può dunque affermare che sia il DSM-V-TR che l'ICD-11 hanno abbandonato la logica dei sottotipi rigidi, adottando un approccio che riflette al meglio il disturbo, considerando la sua eterogeneità e consentendo interventi terapeutici ed educativi più mirati e personalizzati.

—

1.4 Fattori di rischio

Inanzitutto è indispensabile distinguere il significato di cause e fattori di rischio.

Una causa è un elemento che ha un rapporto diretto e determinante con l'insorgenza di una condizione. Nei modelli multifattoriali come l'autismo, non è stata ancora individuata una causa unica e certa.

I fattori di rischio, invece, sono condizioni che aumentano la probabilità di contrarre il disturbo e rendono l'individuo più vulnerabile, ma non sono sufficienti a determinare l'insorgenza del disturbo. I fattori di rischio che riguardano il Disturbo dello Spettro Autistico sono molteplici; tra questi, ad esempio, vi sono quelli di natura epigenetica.

L'epigenetica studia le modifiche dell'espressione genetica non dovute a mutazioni del DNA, ma a influenze ambientali che interagiscono con l'attivazione o la disattivazione dei geni. Tra i meccanismi epigenetici più comuni rientrano:

1. Metilazione del DNA;
2. Modificazioni istoniche;
3. RNA non codificanti.

Negli ultimi anni sono state smentite tutte le ipotesi che legano la vaccinazione alla manifestazione dell'autismo, oggi considerate teorie prive di qualsiasi fondamento scientifico [15].

Sebbene non vi siano studi attendibili che correlino l'insorgenza del disturbo a un singolo fattore ambientale, la letteratura concorda nell'indicare una serie di condizioni che possono aumentare il rischio nei soggetti geneticamente predisposti. Ad esempio, fattori come lo stress, l'esposizione a tossine e il manifestarsi di infezioni durante la gravidanza possono influire alterando l'espressione genica del feto, così da aumentare il rischio di deviazione nello sviluppo neurologico [3].

Pertanto, il Disturbo dello Spettro Autistico non è riconducibile a una causa unica, bensì il modello multifattoriale è, ad oggi, considerato il paradigma più attendibile per spiegare l'eziologia dell'ASD. Il che implica che non sia il singolo evento, gene o l'esposizione ambientale a scatenare l'autismo, piuttosto la combinazione di diversi fattori (genetici, epigenetici e ambientali) in modo specifico, superando la cosiddetta "soglia critica" durante lo sviluppo del sistema nervoso centrale.

Questo processo avviene soprattutto nelle prime fasi di vita o durante la gravidanza (quando il cervello è altamente sensibile agli stimoli interni ed esterni) e influenza processi neurobiologici chiave come:

1. Lo sviluppo sinaptico;
2. La connettività cerebrale;
3. La migrazione neuronale;
4. La regolazione dell'infiammazione e dello stress ossidativo.

—

1.5 Diagnosi classica e relativi limiti

La diagnosi del Disturbo dello Spettro Autistico è un processo complesso, che comprende diversi esami clinici e strumentali [16]. Essa si basa su valutazioni multidimensionali che includono gli aspetti comportamentali, lo sviluppo comunicativo, le capacità sociali e l'anamnesi della persona.

Per questo motivo, l'accertamento clinico coinvolge più figure professionali, tra cui neuropsichiatri infantili, logopedisti e pediatri.

I principali strumenti di valutazione per la diagnosi si fondano sull'osservazione clinica diretta, supportata da strumenti standardizzati che consentono di raccogliere dati oggettivi. Tra i più diffusi troviamo:

- **ADOS-2 (Autism Diagnostic Observation Schedule)**: consente di studiare la comunicazione, le interazioni sociali e i comportamenti attraverso prove strutturate [17];
- **ADI-R (Autism Diagnostic Interview – Revised)**: attraverso interviste semi-strutturate rivolte ai genitori, permette di ricostruire e studiare le prime manifestazioni del disturbo [18];
- Altre scale di screening, come la **CARS (Childhood Autism Rating Scale)** o lo **SCQ (Social Communication Questionnaire)**, utilizzate come strumenti preliminari di valutazione [19].

Nella quasi totalità dei casi, il processo diagnostico inizia con una segnalazione da parte dei genitori o degli insegnanti di scuola, che notano difficoltà del bambino nelle relazioni interpersonali o nella comprensione. A partire da questa segnalazione, si avvia un iter che prevede:

1. Raccolta dell'anamnesi familiare;
2. Interviste ai genitori e colloqui clinici;
3. Osservazione diretta del comportamento in contesti quotidiani;
4. Somministrazione di test standardizzati;
5. Valutazioni complementari.

Sebbene fondamentale, la diagnosi classica presenta alcuni limiti: richiede tempi lunghi, costi elevati e una componente soggettiva che può portare a falsi positivi o falsi negativi, soprattutto nei casi più lievi.

Per questo motivo, la diagnosi classica necessita di aggiornamenti che possano migliorarla in termini di accuratezza e rapidità. Ad oggi, grazie all'implementazione di modelli di *Machine Learning* e *Deep Learning*, si punta a sviluppare sistemi di supporto alla diagnosi capaci di integrare i metodi tradizionali [16].

Questi approcci non hanno lo scopo di sostituire il giudizio clinico, ma di affiancarlo, fornendo strumenti più oggettivi, rapidi e in grado di riconoscere pattern complessi che possono sfuggire all'osservazione umana.

—

Capitolo 2

Intelligenza Artificiale: Machine Learning e Deep Learning

2.1 Fondamenti di Machine Learning

Negli ultimi decenni, l'Intelligenza Artificiale (IA) ha assunto un ruolo sempre più centrale, affermandosi come una delle aree di ricerca e sviluppo più promettenti e rivoluzionarie [20].

Con il termine IA si fa riferimento all'insieme dei metodi che permettono ai sistemi informatici di simulare il cervello umano, sviluppando tecniche come il ragionamento, l'apprendimento e la capacità decisionale.

Il *Machine Learning* è una sotto-disciplina dell'IA e rappresenta uno degli strumenti più efficaci e utilizzati per raggiungerne gli obiettivi. In particolare, si occupa dello sviluppo di algoritmi, modelli matematici e sistemi computazionali in grado di apprendere da dati ed esperienze, migliorando progressivamente le proprie prestazioni senza la necessità di istruzioni da parte di un programmatore [21].

L'idea di fondo è che, fornendo alla macchina una grande quantità di esempi, essa possa essere in grado di individuare schemi ricorrenti o strutture nascoste, per poi, in un secondo momento, compiere previsioni o elaborare nuovi dati.

Gli algoritmi di Machine Learning si possono classificare in tre classi, in base alla modalità con cui i modelli apprendono dai dati:

- **Apprendimento supervisionato (supervised learning):** al modello viene fornito un insieme di dati etichettati, cioè composti da coppie input-output. Questo è il metodo più utilizzato e trova applicazione in compiti di classificazione, come la diagnosi di malattie, oppure in ambito di regressione.
- **Apprendimento non supervisionato (unsupervised learning):** al modello non vengono fornite etichette; quindi, deve individuare autonomamente pattern nascosti, correlazioni o strutture all'interno dei dati.
- **Apprendimento per rinforzo (reinforcement learning):** la macchina interagisce con l'ambiente e impara a prendere decisioni ottimali grazie a un meccanismo di penalità e ricompense.

Il *Deep Learning* (DL) è una branca del Machine Learning che si basa sull'utilizzo di reti neurali artificiali con diversi strati di elaborazione. Il termine "Deep", infatti, si riferisce proprio alla profondità della rete, ossia al numero di livelli che permettono di elaborare e studiare i dati in maniera progressiva e sempre più astratta [22].

Questa metodologia si ispira al funzionamento del cervello umano. Il cervello è costituito da miliardi di neuroni che comunicano tra loro mediante segnali elettrici e chimici. Ogni neurone riceve input dai dendriti, li elabora e, se viene superata una soglia di attivazione, trasmette una risposta attraverso l'assone, stimolando altri neuroni.

Il Deep Learning riprende questa logica attraverso le cosiddette reti neurali artificiali. Gli strati iniziali catturano informazioni preliminari, mentre quelli più profondi riescono a individuare relazioni sempre più nascoste e complesse, così da offrire al modello una comprensione più definita e specifica del problema.

—

2.2 Deep Learning e applicazioni in ambito biomedico

Come già detto, negli ultimi anni l'intelligenza artificiale si è fatta spazio nei più svariati campi applicativi, dalle piattaforme di uso comune come Netflix e Spotify, fino ai sistemi di riconoscimento facciale e vocale integrati negli smartphone.

Nel settore biomedicale, in particolare, le metodologie fondate sull'intelligenza artificiale stanno modificando significativamente le prassi con cui i medici e gli infermieri adoperano per lo studio e la cura di malattie. Quest'aiuto comprende, per esempio, il rilevamento e la classificazione di malattie specifiche, tramite lo studio e l'analisi di dati clinici, omici e immagini biomediche [23].

In questo contesto, le tecniche di Machine Learning (ML) e di Deep Learning (DL) in particolare sono state ampiamente utilizzate per la loro capacità di analizzare grandi quantità di dati, riconoscere modelli specifici e scoprire relazioni funzionali non banali tra input e output.

L'obiettivo non è sostituire la metodologia clinica tradizionale, ma combinare i due approcci per ottenere un impatto positivo sul benessere delle persone.

Il Deep Learning è utilizzato per molteplici compiti, come la segmentazione di strutture anatomiche, l'identificazione di biomarcatori, la classificazione e la previsione di specifiche patologie [24].

Tra gli approcci più innovativi che si basano sul Deep Learning troviamo:

- **Modelli spazio-temporali**: utili per lavorare con dati che rappresentano un'evoluzione nel tempo;
- **Multiple instance-learning**: consente l'apprendimento di modelli a partire da un grande numero di immagini con poche etichette che ne determinano la tipologia di appartenenza;

- **DL per la radiomica in oncologia**: favorisce il supporto alle decisioni cliniche tramite l'analisi delle immagini, identificando caratteristiche peculiari della patologia impercettibili per l'occhio umano.

Lo sviluppo di questi sistemi si basa su una serie di processi che vanno dalla raccolta dei dati, all'elaborazione degli stessi, fino alla definizione di algoritmi che permettono di risolvere il problema affrontato.

Trattandosi di un ambito delicato, che ha un impatto importante sul benessere delle persone, risulta evidente come ogni scelta attuata debba essere opportunamente motivata. Malgrado ciò, i modelli per l'apprendimento e la risoluzione di problemi sono spesso considerati delle "black box", ossia delle scatole nere, per via del fatto che i meccanismi che determinano i risultati e le previsioni sono nascosti o non interpretabili fluidamente dall'essere umano.

Le tecniche di Explainable AI (XAI) nascono con questo obiettivo: fornire risultati più comprensibili e analizzabili, permettendo così di lasciare, in ultima analisi, la possibilità decisionale all'uomo.

Tra le tecniche di XAI vi sono Shapley Additive exPlanations (SHAP) e Gradient-weighted Class Activation Mapping (Grad-CAM). Il metodo SHAP è in grado di estrapolare il contributo di ogni variabile, spiegando quindi come ognuna di queste agisca sul valore finale della predizione. Il Grad-CAM consente invece di dare la possibilità decisionale a un medico, andando ad evidenziare le regioni dell'immagine che hanno maggiormente influenzato la diagnosi [25].

Le applicazioni del Deep Learning in medicina sono vaste e in continua evoluzione. Di particolare rilievo è il suo utilizzo nelle terapie intensive, in cui i dati continui dei monitor possono essere analizzati per prevedere eventi come arresti critici o insufficienze renali acute. Analogamente, il DL può supportare la prognosi di malattie oncologiche utilizzando immagini diagnostiche al posto di procedure più invasive.

Un ulteriore aspetto di grande rilevanza riguarda la predizione dell'insorgenza di malattie. Analizzando dati clinici longitudinali insieme a fattori genetici e ambientali, il Deep Learning consente di identificare schemi che anticipano la comparsa di patologie non ancora manifeste. Questo approccio permette di implementare strategie preventive mirate e di ridurre l'impatto della malattia sul paziente e sui sistemi sanitari.

Un altro ambito in cui queste metodologie trovano spazio è l'elaborazione di cartelle cliniche, per individuare diagnosi non esplicitamente registrate e contribuire così a una migliore classificazione delle malattie. Grazie a questi approcci è possibile, per esempio, suddividere il diabete di tipo 2 in sottocategorie più precise, facilitando terapie mirate e specifiche.

L'area più sviluppata resta però l'interpretazione delle immagini diagnostiche. Tecniche di radiomica, infatti, permettono di analizzare TAC e risonanze magnetiche in modo dettagliato, rilevando caratteristiche non visibili ad occhio nudo e supportando la diagnosi di numerose patologie.

—

2.3 Dataset

L'importanza dei dati per l'Intelligenza Artificiale è cruciale, poiché essi rappresentano il fondamento su cui si basa qualsiasi applicazione, sia del Machine Learning che del Deep Learning.

Il termine *dataset* indica un insieme di dati, raccolti e strutturati in modo da poter essere analizzati o elaborati per addestrare modelli computazionali. I dati raccolti influenzano direttamente le prestazioni dell'algoritmo; per questo motivo, nella fase di costruzione di un dataset è fondamentale prestare particolare attenzione alla loro qualità, completezza e rappresentatività.

Un buon dataset, infatti, dovrebbe essere bilanciato, ossia presentare distribuzioni equilibrate delle diverse classi, e al tempo stesso rappresentativo della popolazione a cui si riferisce.

Esistono varie tipologie di dataset, ad esempio dataset numerici, testuali, di immagini, di segnali e multimodali, che mettono in relazione più fonti informative.

Nel campo biomedico, i dataset possono includere dati clinici, immagini mediche, sequenze genomiche o registrazioni fisiologiche. Queste informazioni rappresentano un elemento indispensabile per lo sviluppo di strumenti predittivi e di supporto alle decisioni cliniche.

Per favorire l'apprendimento automatico, i dataset vengono suddivisi in tre insiemi distinti: *training set*, *validation set* e *test set*. Questa separazione consente di addestrare i modelli, ottimizzarne i parametri ed elaborare i dati in maniera concisa e specifica.

—

2.3.1 Training set

Per addestrare un modello di Machine Learning o di Deep Learning è di fondamentale importanza il *training set* (TS), che costituisce la parte più ampia di un dataset.

In questa fase l'algoritmo acquisisce la capacità di riconoscere schemi e relazioni nascoste presenti nei dati, andando ad adattare progressivamente i propri parametri interni, come pesi e bias, per minimizzare l'errore tra le predizioni effettuate e i reali output.

In genere, il training set rappresenta circa il 60–80% dell'intero dataset. Questa percentuale può però variare a seconda della tipologia di problema affrontato o della quantità di dati disponibili.

Ad esempio, se si lavora con dataset molto ampi si può ridurre la porzione di dati dedicata al training set senza però compromettere le prestazioni dell'algoritmo; al contrario, in scenari in cui si ha un piccolo dataset, è spesso necessario massimizzare la parte dedicata all'addestramento, facendo attenzione a non ridurre eccessivamente il validation set e il test set.

La varietà e la quantità dei dati contenuti nel training set sono determinanti per il successo del modello.

Un training set troppo ridotto o poco rappresentativo potrebbe andare incontro a problemi di *underfitting*, ovvero uno scarso apprendimento che non consente al modello di percepire la complessità del problema.

D'altra parte, un training set molto ampio ma non accuratamente selezionato potrebbe introdurre problemi di rumore e portare a predizioni imprecise.

Il bilanciamento delle classi, invece, rappresenta un importante fattore per la creazione di un buon training set.

Se una classe appartenente a un TS è molto più rappresentata rispetto alle altre, il modello tende a sviluppare una forte distorsione, predicendo quasi sempre la classe dominante. Per ridurre questo problema, una delle strategie adottate è la *data augmentation*, che consiste nella generazione di nuovi campioni sintetici a partire da quelli esistenti. Nel caso dei dati temporali, ad esempio, si possono applicare trasformazioni come l'introduzione di rumore, lievi variazioni di scala o traslazioni temporali. In questo modo si arricchisce il dataset, migliorando la capacità del modello di generalizzare senza alterare la coerenza dei segnali originali.

—

2.3.2 Validation set

Il *validation set* costituisce una parte fondamentale del processo di sviluppo di un modello di Machine Learning o di Deep Learning.

Si tratta di un sottoinsieme del dataset, differente dal training set e dal test set. Lo scopo di questa sottocategoria è valutare le prestazioni del modello durante la fase di addestramento.

Il validation set non partecipa direttamente all'aggiornamento di pesi o bias, ma viene utilizzato per monitorare la capacità di generalizzazione dell'algoritmo su dati che il modello non ha mai analizzato in fase di training.

In questo modo si contrasta il fenomeno di *overfitting*, ossia quando l'algoritmo impara a memoria i dati di addestramento senza riuscire a generalizzare su nuovi esempi.

Nella maggior parte dei casi, il validation set rappresenta il 10–20% dell'intero dataset, anche se questa percentuale può variare in base al numero di dati disponibili o alla complessità del problema.

Dopo ogni epoca, il modello viene esaminato sul validation set grazie a specifiche metriche, come accuratezza, sensibilità, specificità o F1-score, così da valutare se il modello stia effettivamente migliorando senza perdere la capacità di generalizzazione.

—

2.3.3 Test Set

Il *test set* rappresenta la fase finale di valutazione di un modello di Machine Learning o di Deep Learning. Si tratta di un sottoinsieme del dataset, utilizzato esclusivamente dopo la fase di training set.

Lo scopo del test set è verificare se le prestazioni del modello si mantengono elevate su dati completamente nuovi e mai visti durante le fasi precedenti. Di norma, il test set rappresenta circa il 10–20% del dataset complessivo, ma la percentuale, come per il training set e il validation set, può variare a seconda delle caratteristiche del dataset.

—

2.4 Metriche di valutazione

Le *metriche di valutazione* permettono di stabilire in maniera oggettiva la qualità delle predizioni effettuate dal modello e di esaminare i suoi punti di forza e di debolezza.

Esistono diverse metriche, ognuna delle quali è utile in specifici scenari applicativi; per questo non ci si può limitare alla sola *accuracy*, ma è necessario considerare altre metriche che descrivano più nel dettaglio le prestazioni.

In generale, queste metriche vengono calcolate grazie a una matrice di confusione, che mette in relazione le predizioni del modello con i valori reali e distingue veri positivi, veri negativi, falsi positivi e falsi negativi.

La matrice di confusione

Per comprendere appieno le metriche di valutazione è necessario introdurre i concetti fondamentali alla base della *matrice di confusione*. Essa mette in relazione le predizioni del modello con i valori reali e distingue quattro possibili esiti:

- **Vero Positivo (TP)**: il modello predice correttamente la classe positiva. Ad esempio, un paziente realmente affetto da una malattia viene identificato come malato.
- **Vero Negativo (TN)**: il modello predice correttamente la classe negativa. Ad esempio, un paziente sano viene correttamente classificato come tale.
- **Falso Positivo (FP)**: il modello predice come positiva una condizione che in realtà è negativa. Per esempio, un paziente sano viene erroneamente classificato come malato (errore di tipo I).
- **Falso Negativo (FN)**: il modello predice come negativa una condizione che in realtà è positiva. Per esempio, un paziente malato viene erroneamente classificato come sano (errore di tipo II).

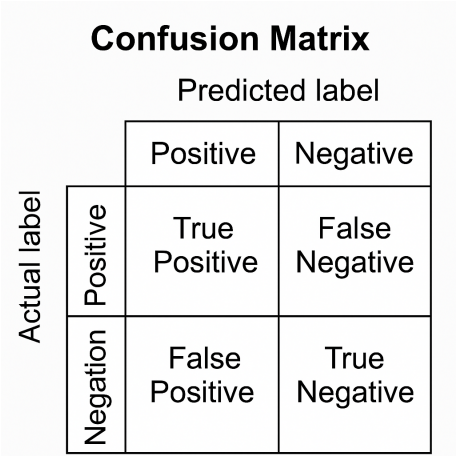


Figura 2.1: Esempio di matrice di confusione con le quattro possibili categorie di predizione.

Le principali metriche utilizzate sono:

- **Accuracy**
- **Precision**
- **Sensitivity o Recall**
- **F1-score**
- **AUC**

—

2.4.1 Accuracy

L'*accuracy* è una delle metriche più importanti per valutare le prestazioni di un modello. Essa indica la percentuale di predizioni corrette sul totale delle osservazioni analizzate.

Matematicamente l'Accuracy è calcolata come:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Questa metrica risulta utile se le classi sono bilanciate, quindi presenti in modo equilibrate nel dataset, e se l'errore ha lo stesso peso in entrambi i casi.

—

2.4.2 Precision

La *precision* è una metrica utilizzata per valutare l'accuratezza delle predizioni positive effettuate da un modello di classificazione. Misura quindi quanto un modello sia preciso quando predice la classe positiva.

La *precision* può essere espressa tramite la seguente formula:

$$Precision = \frac{TP}{TP + FP}$$

Questa metrica risulta particolarmente significativa quando l'obiettivo è ridurre al minimo i falsi positivi. Viene spesso impiegata in scenari in cui un falso allarme può determinare gravi conseguenze, come nella diagnosi medica o nei sistemi di rilevamento delle frodi.

—

2.4.3 Sensitivity

La *sensitivity* (nota anche come *recall* in ambito informatico) è una metrica che misura la capacità di un modello di individuare correttamente i casi positivi.

Si definisce tramite la formula:

$$Sensitivity = \frac{TP}{TP + FN}$$

Questa metrica è particolarmente rilevante in ambito biomedico, poiché un valore basso di sensitivity implica un elevato numero di falsi negativi. In questo contesto, un falso negativo può comportare conseguenze gravi, come ad esempio la mancata diagnosi di una patologia.

—

2.4.4 F1-score

L'*F1-score* è una metrica che combina in un unico risultato i valori di *precision* e *sensitivity*. Viene calcolato tramite la media armonica di queste due grandezze e permette di valutare l'equilibrio tra la capacità del modello di ridurre i falsi positivi e quella di ridurre i falsi negativi.

Può essere espresso con la formula:

$$F1 = 2 \cdot \frac{Precision \cdot Sensitivity}{Precision + Sensitivity}$$

Questa metrica è particolarmente utile in presenza di dataset con classi sbilanciate oppure quando è necessario bilanciare i valori di *sensitivity* e *precision*. Per questo motivo, l'F1-score è spesso preferito rispetto all'*accuracy* in molti ambiti, come quello biomedico, dove è fondamentale analizzare correttamente sia i falsi positivi sia i falsi negativi.

—

2.4.5 AUC

L'*AUC* è una metrica che misura l'area sottesa alla curva ROC (*Receiver Operating Characteristic*). Questa curva rappresenta graficamente la relazione tra il tasso di

veri positivi (True Positive Rate, TPR, equivalente alla *sensitivity*) e il tasso di falsi positivi (False Positive Rate, FPR) al variare della soglia di classificazione del modello.

Il TPR e l'FPR sono definiti come:

$$TPR = \frac{TP}{TP + FN} \qquad FPR = \frac{FP}{FP + TN}$$

L'AUC indica la capacità del classificatore di distinguere correttamente tra le classi:

- AUC $= 1$ indica un modello perfetto,
- AUC $= 0.5$ indica un modello che classifica casualmente (equivalente a un lancio di moneta),
- AUC < 0.5 segnala prestazioni peggiori del caso.

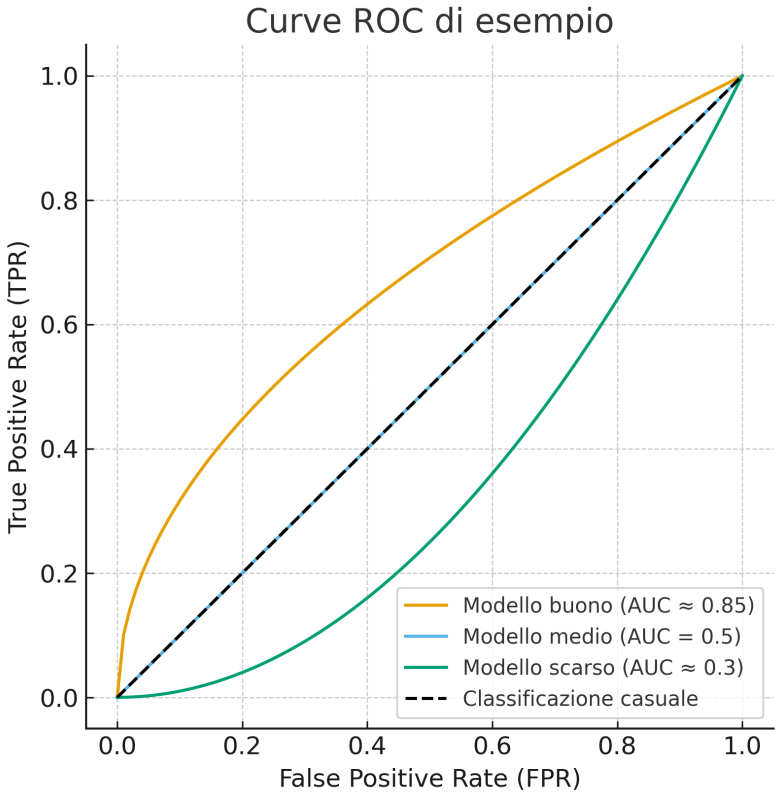


Figura 2.2: Esempio di curve ROC. La curva mostra la relazione tra il tasso di veri positivi (TPR) e il tasso di falsi positivi (FPR) al variare della soglia di classificazione. Si osservano tre modelli con prestazioni differenti: un modello buono (AUC ≈ 0.85), un modello medio (AUC $= 0.5$, classificazione casuale) e un modello scarso (AUC ≈ 0.3).

Questa metrica risulta utile quando si lavora con dataset sbilanciati, poiché essa valuta il comportamento complessivo del modello e non dipende da una singola soglia di decisione.

—

2.5 Data Preprocessing

Il termine *data preprocessing* assume un ruolo fondamentale nel contesto del *Machine Learning* e del *Deep Learning* e rappresenta una fase cruciale per l'elaborazione di un qualsiasi progetto basato su un dataset [26].

Con questa espressione si intende l'insieme dei metodi e dei processi utilizzati per trasformare i dati grezzi in dati più adatti all'analisi e all'addestramento di modelli predittivi. I dati iniziali, infatti, spesso si presentano incompleti, ridondanti, rumorosi e non strutturati, rendendo complesso il loro utilizzo all'interno di un modello.

La pre-elaborazione dei dati si pone quindi l'obiettivo di migliorare la qualità e la coerenza delle informazioni, garantendo che il modello riceva in input dati significativi e comparabili. Grazie a questo processo, si riducono notevolmente i rischi di distorsione nei risultati e si aumenta la capacità di generalizzazione del modello.

Il *data preprocessing* include una fase preliminare di pulizia dei dati, indispensabile per garantire che il dataset sia accurato e coerente. Questo passaggio ha l'obiettivo di rimuovere imperfezioni ed irregolarità che possono compromettere la qualità dei risultati.

Tra le operazioni più comuni troviamo:

- **Gestione dei valori mancanti**, mediante eliminazione delle osservazioni.
- **Rilevamento e gestione degli outlier**, ossia di quei dati anomali che rischiano di distorcere l'apprendimento del modello.
- **Gestione dei duplicati**, per evitare ridondanze e bias nelle predizioni.

Dopo la pulizia dei dati, segue la fase di trasformazione. In questo periodo i dati vengono resi omogenei e comparabili attraverso metodologie come la *normalizzazione* e la *standardizzazione*, così da assicurare un corretto funzionamento degli algoritmi del modello.

—

2.5.1 Gestione dei valori mancanti

I *valori mancanti* sono un problema molto comune nei progetti di *Data Science*, *Machine Learning* e *Deep Learning*. Indipendentemente dall'ambito o dal settore applicativo, ogni dataset può presentare valori nulli o incompleti.

La loro gestione è quindi di fondamentale importanza nello sviluppo di modelli affidabili e accurati. Ignorare questa tipologia di dati comporta la possibile

introduzione di bias nei risultati, interpretazioni distorte dei dati e algoritmi poco efficaci nella risoluzione dei problemi o nelle predizioni. Al contrario, una gestione accurata consente di ottenere analisi più rappresentative e previsioni più precise [27].

Un valore mancante rappresenta l'assenza di un'informazione per una determinata osservazione in una o più parti del dataset. Ciò si verifica quando un valore non viene registrato. Questa condizione può accadere per svariati motivi, ad esempio errori tecnici, difetti nelle apparecchiature di rilevazione o una mancata risposta durante la raccolta di informazioni.

Le cause che scaturiscono i valori mancanti si possono suddividere in tre meccanismi principali:

1. **MCAR (Missing Completely at Random)**: dati mancanti in modo completamente casuale. L'assenza del valore non è influenzata né dalla variabile stessa né da qualsiasi altra variabile. I metodi di imputazione (ad esempio sostituzione con la media o la mediana) funzionano bene poiché la mancanza non altera le caratteristiche del dataset. La rimozione di queste informazioni non introduce bias significativo.

2. **MAR (Missing at Random)**: valori mancanti in modo non casuale, la cui assenza è spiegabile tramite altre variabili presenti nel dataset. Questa tipologia di dati richiede una gestione avanzata, poiché eliminare questi valori può introdurre bias significativo. Una tecnica utilizzata è l'imputazione condizionale, che sfrutta le variabili correlate per stimare i dati mancanti. Tra le metodologie più diffuse vi sono la regressione e l'impiego di algoritmi di *Machine Learning* per stimare i valori mancanti grazie alle altre variabili.

3. **MNAR (Missing Not at Random)**: valori mancanti in modo sistematico, ossia la probabilità di assenza dipende direttamente dal valore stesso della variabile mancante. La gestione di questi dati è la più complessa, in quanto non esistono metodi di imputazione in grado di stimare con precisione i valori senza introdurre bias.

I dati mancanti in un dataset si presentano come celle vuote o valori nulli. In Python, la libreria *Pandas* mette a disposizione funzioni utili ad individuare questa tipologia di dati, come `.isnull()` e `.isna()`. Entrambe restituiscono una matrice booleana, in cui `True` indica la presenza di un dato mancante. Una volta identificati, è possibile calcolare il numero di questi valori tramite la funzione `.sum()`.

[language=Python, Esempio di rilevazione e conteggio dei valori mancanti con Pandas]
import pandas as pd
Creazione di un DataFrame di esempio
df = pd.DataFrame("Nome": ["Anna", "Luca", "Marco", "Giulia"], "Età": [23, None, 35, None])

Individuazione dei valori mancanti
print(df.isnull())
Conteggio dei valori mancanti per colonna
print(df.isnull().sum())

Esistono dati che non sono esplicitamente nulli, ma che potrebbero essere ricavati a partire da altre variabili del dataset. Un esempio tipico è un dataset che contiene l'anno di nascita e l'anno corrente: da queste informazioni è possibile calcolare l'età di una persona. Questa tipologia di valori prende il nome di **dati mancanti contestuali**.

—

2.5.2 Rilevamento e gestione degli outlier

Gli *outlier* sono dati che si discostano sensibilmente dalla distribuzione generale di un dataset.

La loro presenza può essere correlabile a errori di misurazione, errori di inserimento di dati o rumore nei sistemi di acquisizione.

Gli *outlier* possono influenzare in modo significativo l'affidabilità dei risultati o l'addestramento del modello, poiché i valori estremi possono alterare le statistiche descrittive, falsare le relazioni tra variabili e ridurre la capacità predittiva degli algoritmi.

Quando in un training set sono presenti *outlier*, il modello può diventare eccessivamente sensibile, causando *overfitting*.

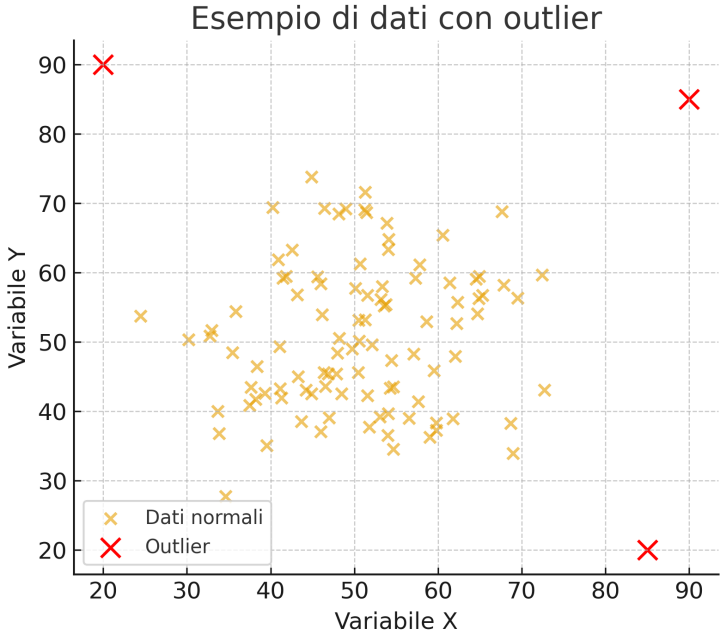


Figura 2.3: Esempio di distribuzione di dati con la presenza di *outlier* (in rosso), che si discostano sensibilmente dal gruppo principale di osservazioni (in giallo).

Le principali tecniche per gestirli sono:

1. **Individuazione statistica**: tramite metodi come lo *z-score* (distanza dal valore medio in termini di deviazione standard) o l'intervallo interquartile (IQR), che identifica come outlier i valori troppo distanti dai quartili.

2. **Individuazione grafica**: mediante rappresentazioni visive come il boxplot, scatterplot o istogrammi, che consentono di osservare la presenza di valori anomali.

3. **Trattamento degli outlier**: attraverso la rimozione o la trasformazione dei dati tramite logaritmi o *robust scaling*.

—

2.5.3 Gestione dei duplicati

I *dati duplicati* in un dataset sono righe ripetute che rappresentano la stessa osservazione reale. Sono causati da errori umani, unione di più dataset o malfunzionamenti nei processi di acquisizione.

La presenza di duplicati può causare svariati problemi, ad esempio analisi distorte, poiché alcuni record pesano più del dovuto, aumento del rumore e rischio di *overfitting*.

Per gestire i duplicati si possono utilizzare diverse metodologie, tra cui:

1. **Individuazione dei duplicati**: tramite funzioni Pandas come `duplicated()` o altri metodi di confronto righe su colonne chiave, per verificare se due record rappresentano la stessa osservazione.

2. **Scelta del criterio di unicità**: impostare su quali colonne ci si deve basare per stabilire se due righe sono duplicate.

3. **Rimozione o mantenimento delle occorrenze**: mediante funzioni come `drop_duplicates(keep='first')`, che mantiene la prima delle occorrenze; `keep='last'`, che preserva l'ultima; oppure `keep=False`, che rimuove tutte le righe duplicate.

4. **Standardizzazione prima dell'individuazione**: effettuare una pulizia dei dati (minuscole, maiuscole, spaziature, punteggiature), per evitare duplicati apparenti causati da formattazioni diverse.

Come indicato in [28], queste tecniche sono ampiamente utilizzate nella data science per garantire la qualità dei dati.

—

2.5.4 Normalizzazione

La *normalizzazione* è una delle metodologie più utilizzate nel preprocessing dei dati e consiste nel trasformare i valori delle variabili numeriche entro un intervallo predefinito, solitamente compreso tra 0 e 1 o, in alcuni casi, tra -1 e 1.

L'obiettivo principale è quello di rendere confrontabili variabili che, altrimenti, possono presentare scale molto differenti tra loro.

Un esempio utile per comprendere la normalizzazione è un dataset che include l'età di un cittadino (espressa in anni) e il suo reddito (espresso in euro). In questo caso, il reddito presenta valori numerici di gran lunga superiori rispetto all'età e, se dovessimo applicare un algoritmo di Machine Learning direttamente su questi dati, la variabile "reddito" finirebbe per influenzare notevolmente i risultati a causa della scala numerica elevata. La normalizzazione, quindi, evita questo problema ridimensionando entrambe le variabili all'interno di un intervallo di valori comune.

Esistono diverse formule per la normalizzazione; la più comune è la *Min-Max Scaling*, che si applica mediante la seguente formula:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

dove x rappresenta il valore originale della variabile, $x_{\min}$ e $x_{\max}$ i valori minimo e massimo della stessa, e x' il valore normalizzato. In questo modo, il valore minimo della variabile viene trasformato in 0, il massimo in 1 e tutti gli altri valori vengono compressi proporzionalmente all'interno di tale intervallo.

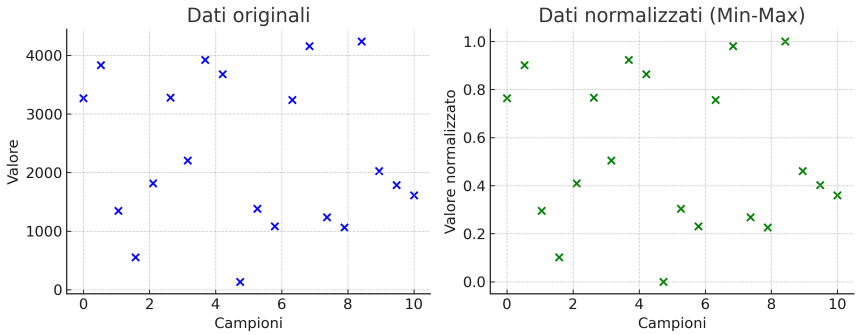


Figura 2.4: Esempio di normalizzazione con Min-Max Scaling: a sinistra i dati originali, a destra i dati trasformati nell'intervallo [0,1].

La normalizzazione ha diversi campi di applicazione; in particolare, trova utilità negli algoritmi che si basano sul calcolo di distanze o similarità tra osservazioni, come il *K-Nearest Neighbors (KNN)*, le *Support Vector Machine (SVM)* con kernel e le reti neurali. In questi modelli, se le variabili non sono poste sulla stessa scala, si aumenta il rischio di distorsione nei risultati finali.

Un ulteriore vantaggio della normalizzazione è che, trasformando i dati entro un intervallo limitato, si riduce il rischio di instabilità numerica, soprattutto in algoritmi che utilizzano calcoli matriciali o gradienti. La normalizzazione, invece,

risulta non adatta se i dati presentano una distribuzione gaussiana, poiché in tali scenari è consigliato utilizzare la standardizzazione [29].

—

2.5.5 Standardizzazione

La *standardizzazione*, come la normalizzazione, è un'altra tecnica molto diffusa nell'ambito del preprocessing dei dati. Consiste nel trasformare i valori delle variabili in modo tale che abbiano media pari a zero e deviazione standard pari a uno.

Questa metodologia consente di riportare le variabili su una scala comune, eliminando l'influenza legata alle diverse unità di misura o alle diverse varianze.

La formula generale è nota come *z-score scaling* e si applica con la seguente espressione:

$$x' = \frac{x - \mu}{\sigma}$$

dove x rappresenta il valore originale della variabile, μ la media della variabile e σ la sua deviazione standard. Di conseguenza, un valore trasformato x' indica di quante deviazioni standard il valore originale x si discosta dalla media della variabile.

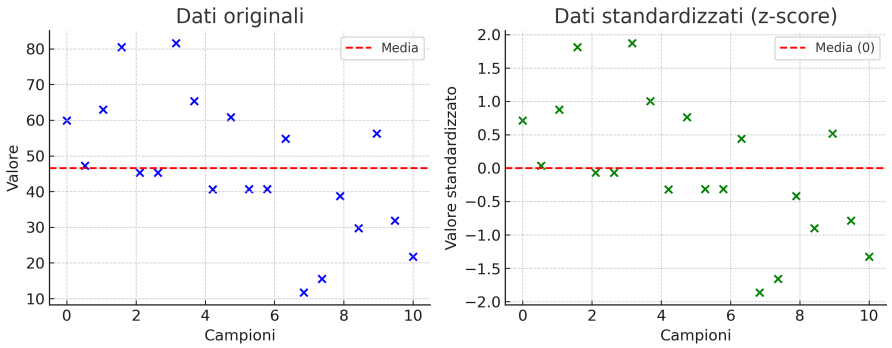


Figura 2.5: Esempio di standardizzazione tramite z-score: a sinistra i dati originali con media diversa da zero, a destra i dati trasformati con media pari a 0 e deviazione standard pari a 1.

Questo metodo di preprocessing trova applicazione quando si lavora con modelli che assumono una distribuzione normale (o gaussiana) dei dati. In tali casi, infatti, applicare la standardizzazione consente di sfruttare al meglio le proprietà statistiche della distribuzione, rendendo più precisi sia i processi di stima sia quelli di ottimizzazione [30].

Variabili con unità di misura differenti, come ad esempio il peso e l'altezza, possono interferire tra loro poiché una delle due potrebbe dominare l'analisi statistica a causa della maggiore ampiezza della propria scala. Attraverso la standardizzazione, le due variabili vengono rese confrontabili e comparabili, e ciò permette di valutare in maniera bilanciata le loro relazioni con la variabile dipendente.

Gli algoritmi di Machine Learning in cui la standardizzazione è più comunemente utilizzata sono la *regressione lineare e logistica*, l'*analisi delle componenti principali (PCA)*, gli *algoritmi bayesiani* e le *reti neurali*.

Rispetto alla normalizzazione, la standardizzazione non vincola le variabili entro un intervallo definito. I dati, quindi, non essendo compressi artificialmente e mantenendo la loro struttura di distribuzione, possono assumere valori molto elevati, che potrebbero creare problemi in alcuni modelli sensibili a valori estremi.

—

2.5.6 Encoding delle variabili categoriche

Un passaggio fondamentale quando si parla di *data preprocessing* riguarda la gestione delle *variabili categoriche*, ossia variabili che assumono valori discreti e non numerici, appartenenti a un insieme finito di categorie.

Esempi tipici sono il genere di un individuo, il colore di un oggetto o il livello di istruzione.

Gli algoritmi di Machine Learning lavorano su dati numerici. Per questo motivo, le variabili categoriche non possono essere utilizzate direttamente, ma devono essere convertite in un formato numerico attraverso un processo di *encoding*.

Tra i metodi di encoding troviamo:

- **Label Encoding**: associa a ciascuna categoria un valore intero (ad esempio *uomo = 0, donna = 1*).
- **One-Hot Encoding**: crea una variabile binaria per ciascuna categoria, assumendo il valore 1 se l'osservazione riguarda quella categoria e 0 altrimenti.
- **Ordinal Encoding**: utilizzato esclusivamente se tra le categorie esiste un ordine naturale (ad esempio *basso = 1, medio = 2, alto = 3*).

—

2.5.7 Bilanciamento delle classi

Non sempre le categorie delle variabili target sono equamente rappresentate. Questo fenomeno, noto con il termine di *class imbalance*, si verifica quando alcune classi presentano un numero di campioni significativamente maggiore rispetto ad altre.

Nell'ambito biomedico questo evento è molto comune: molti dataset clinici sono caratterizzati da migliaia di campioni appartenenti alla classe "sana", mentre la classe "malato" conta soltanto poche decine di osservazioni. In questi casi, un modello di Machine Learning rischierebbe di imparare a predire quasi sempre la classe più frequente, ottenendo scarse capacità predittive sulle classi minoritarie, che spesso sono quelle di maggior interesse.

Il bilanciamento delle classi può essere effettuato tramite diverse tecniche [31]:

- **Oversampling**: consente di aumentare il numero di campioni che rappresentano la classe minoritaria, ad esempio creandone copie o generandone di nuovi attraverso metodi come *SMOTE (Synthetic Minority Oversampling Technique)*.
- **Undersampling**: consiste nella riduzione del numero di campioni della classe maggioritaria, selezionando solo una porzione di dati da preservare per riequilibrare la distribuzione.
- **Class weights**: non si modifica il dataset, ma si interviene direttamente sull'algoritmo, attribuendo un peso maggiore agli errori commessi sulle classi minoritarie.

La scelta della metodologia dipende dal tipo di problema affrontato: se si predilige la preservazione delle informazioni, è consigliato utilizzare l'oversampling che, però, può aumentare il rischio di overfitting; l'undersampling riduce il rischio di overfitting, ma comporta una perdita di dati utili; i class weights, invece, rappresentano una soluzione spesso efficace e meno invasiva.

—

2.6 Feature selection

La *feature selection* rappresenta un passaggio fondamentale per lo sviluppo di modelli di apprendimento automatico. Con questo termine si fa riferimento al processo attraverso il quale vengono selezionate le variabili utili, scartando quelle superflue.

La maggior parte dei dataset è caratterizzata da un'elevata dimensionalità e l'utilizzo di tutte queste informazioni può compromettere le prestazioni del modello, andando ad aumentare sensibilmente i tempi di calcolo o includendo informazioni poco significative o fuorvianti.

Questo fenomeno, noto come *curse of dimensionality*, può essere mitigato tramite la feature selection, che consente di analizzare i dati che contribuiscono maggiormente al risultato, evidenziando i principali biomarcatori e facilitando la relazione tra scienziati dei dati e specialisti clinici.

La riduzione delle feature è di fondamentale importanza anche per conferire maggiore robustezza al modello. Le variabili rumorose o irrilevanti, infatti, possono indurre l'algoritmo a ricercare pattern casuali che non hanno un reale valore predittivo, aumentando il rischio di overfitting. Applicando la feature selection permettiamo al modello di preservare soltanto le informazioni più rappresentative, garantendo maggiore stabilità, affidabilità e accuratezza.

Tra i principali metodi di feature selection troviamo:

1. **Filter methods**
2. **Wrapper methods**

3. **Embedded methods**

—

2.6.1 Filter methods

I *filter methods*, nell'ambito della *feature selection*, si basano sull'applicazione di criteri statistici o misure di correlazione per valutare l'importanza di ciascuna variabile, indipendentemente dal modello di apprendimento utilizzato [32].

Il processo di selezione delle variabili, quindi, non dipende dall'algoritmo di classificazione, bensì viene effettuato prima della fase di addestramento, basandosi esclusivamente su proprietà intrinseche dei dati.

Tra i vantaggi di questa metodologia troviamo una rapidità di esecuzione che permette di lavorare anche in presenza di dataset di grandi dimensioni. Tuttavia, questa tecnica tende a considerare ogni feature in maniera indipendente, trascurando le possibili interazioni tra variabili.

Per questo motivo, i filter methods vengono spesso affiancati da metodi più complessi.

I filter methods possono essere implementati attraverso diverse tecniche statistiche che hanno la finalità di valutare la rilevanza delle variabili rispetto alla variabile target.

Tra le più comuni troviamo:

1. **Test del chi-quadro (χ^2)**: utilizzato in genere con variabili categoriche, consente di verificare se esiste una correlazione significativa tra ciascuna feature e la variabile di output.

2. **ANOVA (Analysis of Variance)**: utile per variabili numeriche, valuta la capacità di una feature di distinguere tra gruppi o classi differenti.

3. **Correlazione di Pearson**: scarta variabili altamente ridondanti valutando la forza e la direzione della relazione lineare tra una feature continua e la variabile target.

4. **Information Gain e Mutual Information**: stimano la quantità di informazione che una variabile fornisce riguardo alla variabile target.

—

2.6.2 Wrapper methods

I *wrapper methods*, a differenza dei filter methods, non si limitano solamente a valutare le variabili sulla base di semplici criteri statistici, bensì sfruttano direttamente le prestazioni del modello di apprendimento automatico per determinare l'importanza delle variabili [33].

Il processo di wrapper methods consiste nel testare diverse combinazioni di feature e nel valutare la qualità delle predizioni ottenute grazie a metriche come l'accuratezza o l'errore di classificazione.

Grazie ai wrapper methods siamo in grado di individuare insiemi di feature che, seppur poco significative prese singolarmente, risultano molto efficaci e predittive se analizzate in combinazione.

I limiti di questa tecnica comprendono costi computazionali elevati, rischio di overfitting e difficoltà di interpretazione, poiché il processo esplora combinazioni di feature senza fornire spiegazioni esplicite sul motivo della loro selezione.

I wrapper methods possono essere implementati attraverso diverse strategie, tra cui:

1. **Forward Selection**: le feature vengono aggiunte progressivamente, migliorando le prestazioni del modello fino al raggiungimento di un insieme ottimale;

2. **Backward Elimination**: si parte dall'insieme completo delle feature e si eliminano, una per volta, quelle che forniscono meno contributo alla performance;

3. **Stepwise Selection**: combina i processi di Forward Selection e Backward Elimination, aggiungendo ed eliminando feature con lo scopo di bilanciare complessità e accuratezza;

4. **Recursive Feature Elimination**: addestra ripetutamente il modello, eliminando progressivamente le variabili meno rilevanti.

—

2.6.3 Embedded methods

Gli *embedded methods* rappresentano una combinazione dei vantaggi dei filter methods e dei wrapper methods, in quanto la selezione delle variabili non avviene prima o dopo l'addestramento, ma è parte integrante del processo di training del modello.

Durante l'addestramento, infatti, è l'algoritmo stesso ad essere in grado di valutare l'importanza delle feature e di penalizzare quelle meno rilevanti, riducendone il peso o eliminandole. Per questo motivo, gli embedded methods sono considerati molto efficienti dal punto di vista computazionale, evitando di esplorare ogni possibile combinazione di variabili [34].

I vantaggi di questi metodi ricadono soprattutto nel bilancio tra efficienza e accuratezza, garantendo buone prestazioni senza i costi computazionali elevati tipici dei wrapper methods. Tuttavia, i risultati ottenuti dipendono fortemente dall'algoritmo del modello scelto.

Tra i principali algoritmi troviamo:

1. **Regressione LASSO (Least Absolute Shrinkage and Selection Operator)**: applica una penalizzazione L1 ai coefficienti del modello, portando a zero quelli meno significativi e scartando le variabili irrilevanti;

2. **Alberi decisionali**: valutano l'importanza delle feature basandosi sulla loro capacità di ridurre l'impurità dei nodi;

3. **Random Forest**: considerano la media della riduzione di impurità dei nodi ottenuta nei diversi alberi;

4. **Gradient Boosted Trees (come XGBoost o LightGBM)**: stimano le variabili più rilevanti, valutando il contributo di ciascuna feature;

5. **Support Vector Machines con regolarizzazione**: limitano il peso delle feature e preservano le variabili con maggiore contenuto informativo.

—

Capitolo 3

Modello di Deep Learning per la predizione del Disturbo dello Spettro Autistico

3.1 Descrizione del dataset

Il dataset utilizzato[35] in questo progetto di tesi proviene da uno studio sperimentale fondato su tecniche di *eye-tracking*, una metodologia che monitora i movimenti oculari di un paziente, con lo scopo di rilevare e distinguere due principali classi: individui con Disturbo dello Spettro Autistico e soggetti con sviluppo tipico (TD – Typically Developing). L'idea di fondo è che l'analisi dei pattern visivi possa evidenziare caratteristiche peculiari nei soggetti con ASD, fornendo così un ulteriore supporto nella diagnostica dei pazienti, spesso lunga, costosa e fortemente dipendente dall'osservazione clinica.

Il dataset è costituito da 59 partecipanti, un campione numericamente contenuto ma adeguato a costituire una base sperimentale preliminare. I soggetti sono stati suddivisi in maniera quasi equilibrata: 29 individui con diagnosi di ASD e 30 soggetti neurotipici. L'equilibrio tra le due classi rappresenta un vero e proprio punto di forza, poiché riduce gli effetti del *class imbalance*, molto comune negli studi biomedici, dove solitamente i casi patologici sono in numero minore rispetto al gruppo di controllo.

Per ciascun partecipante sono state raccolte diverse informazioni, tra cui:

- **ParticipantID**: identificativo univoco assegnato a ciascun soggetto, utile per collegare i dati clinici ai corrispondenti output di eye-tracking;
- **Genere (Gender)**: maschio (M) o femmina (F);
- **Età (Age)**: espressa in anni con valori decimali, che permettono di avere una misura più precisa dello sviluppo cronologico del soggetto;
- **Classe diagnostica (Class)**: categoria binaria che distingue i partecipanti con diagnosi di ASD dai soggetti a sviluppo tipico (TD);

- **CARS Score**: punteggio ottenuto alla *Childhood Autism Rating Scale*, disponibile per un sottoinsieme di 29 partecipanti con ASD. Questo indice fornisce una valutazione quantitativa della gravità della sintomatologia autistica, risultando un importante indicatore clinico.

Oltre ai dati anagrafici e clinici, il dataset include anche i tracciamenti oculari registrati durante specifici compiti visivi, misurati attraverso particolari dispositivi di eye-tracking. Tra le variabili troviamo la posizione delle pupille (in coordinate pixel e millimetri), la posizione del punto di fissazione (*point of regard*), le traiettorie dello sguardo e altri pattern che descrivono il comportamento visivo del soggetto. Queste informazioni, tramite preprocessamento e trasformate in sequenze temporali, permettono di analizzare la dinamica dello sguardo e di rilevare le sottili differenze tra i due gruppi.

Questo dataset può essere considerato **multimodale**, poiché integra dati clinici e demografici, che forniscono informazioni sui pazienti, e i dati sperimentali di eye-tracking, che costituiscono le misure oggettive e ad alta risoluzione dei comportamenti visivi. Questa combinazione consente di integrare le osservazioni cliniche tradizionali con segnali quantitativi e standardizzati, tipici dei modelli di Machine Learning e Deep Learning.

Tuttavia, la limitazione principale di questo dataset è la presenza di variabili mancanti, in particolare il punteggio CARS, presente solo per una parte dei soggetti ASD, che riduce la ricchezza informativa dei metadati.

—

3.2 Preprocessing per il modello LSTM

Il preprocessing dei dati ha aiutato il mio lavoro di tesi nel trasformare dati eterogenei (metadati clinici e misure di eye-tracking) in un formato coerente, pulito e sequenziale, idoneo all'addestramento di una rete LSTM bidirezionale [36].

Il flusso seguito può essere sintetizzato in cinque passi: **pulizia**, **omogeneizzazione delle scale**, **codifica del target**, **costruzione di sequenze temporali** e **preparazione dei set di train/validation con bilanciamento delle classi**.

La pulizia dei dati si è svolta mediante:

1. **Integrazione delle fonti**: sono stati caricati i metadati del dataset, in cui i due livelli informativi sono stati ricondotti a un unico dataframe di lavoro.

2. **Controlli su valori mancanti e formati**: sono stati analizzati i NaN nelle colonne di interesse e i valori non numerici sono stati convertiti in NaN.

3. **Mappatura delle categorie**: è stata integrata una funzione di mapping per ricondurre le etichette presenti nel dataset a ASD, TD oppure Other/Unidentified. Ai fini del lavoro sono stati mantenuti solo i soggetti con etichetta chiara (ASD, TD).

4. **Anomalie e duplicati**: non sono emerse variabili duplicate evidenti; eventuali outlier, invece, sono stati gestiti nella fase di standardizzazione.

Le feature numeriche di eye-tracking sono caratterizzate da scale differenti (pixel, millimetri, conteggi). Per evitare che una di queste misure prevalga sulle altre, è stata applicata la **standardizzazione z-score** tramite `StandardScaler` (media 0 e varianza 1). Questa scelta è particolarmente adatta ai modelli LSTM, sensibili alla stabilità numerica della sequenza in ingresso.

La variabile **Participant Group** è stata convertita in etichette numeriche mediante la funzione `LabelEncoder`, ottenendo il vettore y. La codifica è binaria (TD = 0, ASD = 1) e compatibile con la loss adottata in addestramento.

Poiché i tracciamenti oculari sono serie temporali, gli input sono stati convertiti in sequenze con una finestra scorrevole di ampiezza **WINDOW_SIZE = 10** grazie alla funzione `make_sequences`, che sviluppa:

- **X_seq**, un tensore di forma $(n_sequenze, window_size, n_feature)$, che raccoglie dieci osservazioni consecutive per ciascun istante;
- **y_seq**, un vettore di etichette corrispondenti all'istante $t + window$.

Questa strategia permette di catturare **pattern dinamici** che difficilmente emergerebbero da istantanee isolate.

Per la suddivisione del dataset è stato utilizzato uno **split 80/20** tra train e validation, con **stratificazione su y_seq** per mantenere in validation la stessa proporzione di classi osservata nel training.

Nonostante il dataset sia equilibrato tra le due classi, dopo la trasformazione in sequenze possono svilupparsi leggere asimmetrie. Per questo motivo si sono calcolati i **pesi di classe** con `compute_class_weight`, che sono stati passati al processo di training. In altre parole, gli errori sulla classe minoritaria hanno ricevuto maggior peso nella funzione di perdita, riducendo possibili bias del modello verso la classe più frequente.

—

3.3 Creazione delle sequenze temporali

Un passaggio fondamentale nella fase di preprocessing è stato quello di trasformare i dati di eye-tracking, inizialmente disponibili in formato tabellare, in sequenze temporali perfette per l'elaborazione da parte di un modello LSTM. I tracciamenti oculari, infatti, non rappresentano valori statici, bensì descrivono l'evoluzione dinamica dello sguardo nel tempo.

Analizzare questi istanti isolati non sarebbe stato sufficiente per catturare la complessità dei comportamenti visivi. Il movimento oculare è caratterizzato da diverse dinamiche, ad esempio fissazioni, saccadi e transizioni.

Per questo si è adottata la tecnica del windowing, che consente di suddividere le serie temporali in finestre sovrapposte di lunghezza fissa. Ogni finestra descrive un contesto locale sul quale il modello apprende pattern ricorrenti.

La funzione `make_sequences` ha permesso di costruire una finestra di osservazioni consecutive scorrendo lungo l'asse temporale dei dati.

Come output si ottengono una X_seq, un tensore tridimensionale che raccoglie le feature per ciascuna finestra, e una Y_seq, contenente l'etichetta corrispondente all'istante successivo alla finestra considerata.

Quindi, partendo da un dataset tabellare, si ottiene una rappresentazione sequenziale coerente con le esigenze di una rete LSTM.

La scelta del parametro WINDOW_SIZE = 10 è attribuita al fatto che una finestra troppo corta non sarebbe stata in grado di catturare le informazioni temporali sufficienti, mentre una troppo lunga avrebbe introdotto ridondanza e rischiato di aumentare notevolmente i costi computazionali senza reali benefici sulle prestazioni.

Il valore 10, quindi, si è dimostrato un ottimo compromesso tra livello di precisione e complessità computazionale, favorendo la raccolta di dinamiche dello sguardo senza appesantire eccessivamente l'elaborazione.

—

3.4 Architettura del modello

Lo sviluppo dell'architettura del modello costituisce la fase centrale dell'intero progetto di tesi, poiché le scelte effettuate a livello della struttura hanno un impatto diretto sulle performance del modello, sulla sua interpretabilità e sulla precisione delle predizioni. In un ambito delicato come quello biomedico, ogni dettaglio architetturale deve essere analizzato e valutato con estrema attenzione.

—

3.4.1 Scelta della BiLSTM

La scelta di utilizzare una Long Short-Term Memory bidirezionale (BiLSTM) [37] nasce dall'esigenza di rilevare con la massima precisione possibile tutte le dipendenze temporali presenti nei dati. Queste tipologie di reti superano i limiti delle reti ricorrenti tradizionali (RNN), gestendo sequenze lunghe ed evitando problemi come il *vanishing gradient*, ovvero la progressiva riduzione del valore dei gradienti durante il *backpropagation* che rende difficile l'aggiornamento dei pesi nelle prime unità della rete. Ciò è reso possibile grazie ai meccanismi di cella, input gate, forget gate e output gate [38].

L'estensione bidirezionale permette inoltre di analizzare le informazioni provenienti sia dal passato che dal futuro, rendendo l'analisi più esauriente.

In questo specifico caso, questo aspetto si rileva cruciale per via del fatto che i dati di eye-tracking non sono indipendenti istante per istante, bensì rispondono a dinamiche contestuali che si sviluppano nel tempo. Integrare segnali precedenti e successivi consente quindi di ottenere una rappresentazione realistica, fedele e accurata del comportamento visivo.

—

3.4.2 Descrizione dell'architettura

L'architettura impiegata segue una logica gerarchica, in cui ogni strato del modello ha un compito specifico e contribuisce in maniera complementare alla costruzione della rappresentazione finale:

1. **Input sequenziale** [36, 37]: il modello riceve come input sequenze temporali ottenute tramite windowing. Ognuna di esse è costituita da un segmento di osservazioni continuo, che racchiude l'evoluzione dinamica dello sguardo in un dato intervallo di tempo. Questa fase permette di convertire dati statici in sequenze adatte all'elaborazione di una rete LSTM.

2. **Primo strato BiLSTM (128 unità)**: adempie da livello di estrazione ad alta capacità, in grado di catturare pattern complessi. La scelta di un numero elevato di unità non è casuale, bensì aiuta il modello ad avere una ricca base rappresentazionale su cui costruire i livelli successivi.

3. **Secondo strato BiLSTM (64 unità)**: livello che riduce la dimensionalità preservando solo le informazioni più rilevanti. Questo strato si comporta da filtro, consolidando gli aspetti discriminanti che caratterizzano le due classi in analisi (ASD e TD).

4. **Strato Dense con 64 unità, attivazione ReLU** [39]: consente di combinare le feature temporali in una rappresentazione densa e non lineare. La funzione di attivazione ReLU è indispensabile per favorire la convergenza durante l'addestramento e riduce il rischio di *vanishing gradient* rispetto ad altre funzioni come la sigmoide.

5. **Batch Normalization** [40]: normalizza le attivazioni intermedie e stabilizza il processo di apprendimento. Riduce la sensibilità del modello rispetto all'inizializzazione dei pesi e accelera i tempi di convergenza.

6. **Dropout** [41]: riduce il rischio di overfitting disattivando alcuni neuroni casualmente e costringendo la rete a non dipendere eccessivamente da specifiche connessioni.

7. **Output Dense (2 unità, Softmax)** [42]: rappresenta lo strato finale del modello e fornisce una distribuzione di probabilità su entrambe le classi target. La funzione Softmax è implementata per compiti di classificazione binaria e permette un'interpretazione immediata dei risultati.

Ogni scelta architetturale è stata dettata da una combinazione di fattori pratici e teorici. L'utilizzo di due livelli BiLSTM permette di analizzare i dati su più livelli di astrazione, favorendo la sensibilità del modello rispetto a pattern temporali sottili. Il layer Dense e ReLU aggiunge la capacità di modellare relazioni complesse, mentre Batch Normalization e Dropout donano stabilità e robustezza al modello nella fase di addestramento. La Softmax, infine, traduce i risultati in termini

probabilistici, permettendo di trasmettere con chiarezza le predizioni del modello anche a professionisti non esperti di Machine Learning [43].

—

3.5 Tecniche di ottimizzazione e regolarizzazione

La fase di addestramento di una rete neurale profonda non dipende soltanto dall'architettura, ma anche dalle scelte relative all'ottimizzazione e alle strategie di regolarizzazione. Queste metodologie sono fondamentali per migliorare la convergenza dell'algoritmo, ridurre l'overfitting e fornire al modello la capacità di generalizzare su dati non osservati in fase di addestramento. Nel lavoro svolto sono state utilizzate diverse tecniche.

Per la classificazione binaria è stata adottata la funzione di

perdita `sparse_categorical_crossentropy`. Essa consente di gestire in maniera diretta target etichettati come interi, evitando la necessità di una codifica one-hot. Questa funzione misura la distanza tra le probabilità stimate dal modello e le etichette reali, fornendo un segnale di errore per il processo di backpropagation.

L'ottimizzazione, invece, è stata applicata grazie all'algoritmo Adam [44], utilizzato per le sue caratteristiche di efficienza e la capacità di combinare i vantaggi di AdaGrad e RMSProp. Adam aggiorna i pesi in modo adattivo tramite stime dei momenti primo e secondo del gradiente, favorendo quindi una convergenza rapida anche in presenza di dataset rumorosi o poco bilanciati. Il learning rate è stato inizialmente fissato a 10^{-3}, successivamente regolato dinamicamente durante l'addestramento tramite la callback `ReduceLROnPlateau` [45].

Per ridurre il possibile overfitting, è stato impiegato un meccanismo di

`EarlyStopping` [46] con monitoraggio della metrica di accuratezza sul validation set. Se per sette epoche consecutive non si osserva un miglioramento, l'addestramento viene interrotto e i pesi vengono ripristinati. Questo approccio migliora la capacità di generalizzazione del modello evitando che la rete impari rumore o dettagli specifici del dataset di training.

Al contempo, è stata utilizzata la tecnica di `ReduceLROnPlateau` che permette di ridurre il learning rate di un fattore pari a 0,5 quando la funzione di perdita di validazione non mostra miglioramenti per alcune epoche consecutive. Questo accorgimento permette di rallentare l'aggiornamento dei pesi man mano che l'ottimizzazione procede, favorendo una discesa più mirata verso i minimi locali, migliorando la stabilità della convergenza.

Infine, è stata applicata una callback personalizzata per stampare in tempo reale l'andamento dell'accuracy di validazione a ogni epoca. Questa funzione si rivela utile per monitorare le prestazioni del modello durante il training e diagnosticare rapidamente eventuali anomalie.

—

3.6 Training del modello

La fase di training rappresenta un momento cruciale per lo sviluppo del modello predittivo, in quanto permette alla rete neurale di imparare dalle caratteristiche specifiche dei soggetti appartenenti alle due diverse classi (ASD, TD) a partire dalle sequenze temporali costruite nel preprocessing.

Per fornire una valutazione attendibile delle prestazioni, il dataset è stato suddiviso in due parti secondo una proporzione 80/20, con l'80% dei campioni destinato all'addestramento e il restante 20% riservato alla validazione. La suddivisione è stata applicata in maniera stratificata, così da preservare al massimo la distribuzione delle classi ed evitare il rischio di squilibri che possono compromettere la fase di validazione.

Gli iperparametri utilizzati hanno avuto un ruolo fondamentale nel definire la stabilità e la qualità dell'addestramento. Tra questi troviamo:

1. Batch size = 64, che consente di bilanciare l'efficienza computazionale e la stabilità della discesa del gradiente.

2. Numero di epoche = 60, scelto dopo una serie di test preliminari in cui si è osservato che il modello convergeva in un intervallo compreso tra 40 e 55 epoche.

3. Window size = 10, permette di fornire al modello un contesto temporale sufficiente ad analizzare le dinamiche dell'eye-tracking senza introdurre eccessiva complessità computazionale.

Durante il periodo di addestramento, l'andamento delle metriche è stato sorvegliato tramite i grafici di accuracy e loss per i set di training e validation. L'accuracy di training ha evidenziato un incremento progressivo e regolare; invece, la curva di validazione ha mostrato alcune oscillazioni, tipiche dei modelli LSTM a causa della loro sensibilità ai dati sequenziali e al problema del gradiente.

Tuttavia, queste oscillazioni sono state contenute grazie a due strategie, ovvero l'uso della regolarizzazione con Dropout, che ha ridotto notevolmente il rischio di overfitting, e l'introduzione delle callback di Early Stopping e ReduceLROnPlateau, che hanno rispettivamente interrotto l'addestramento al raggiungimento di un plateau nelle prestazioni e adattato dinamicamente il learning rate per migliorare la convergenza.

Tra le principali difficoltà incontrate vi è stata la necessità di un accurato tuning degli iperparametri. In particolare, i primi esperimenti hanno mostrato episodi di overfitting, con un divario crescente tra l'accuracy di training e quella di validazione.

Questa problematica è stata superata intervenendo su tre aspetti principali:

1. Riduzione del tasso di apprendimento (learning rate), inizialmente impostato a valori elevati che scaturivano oscillazioni troppo marcate della funzione di loss.

2. Aumento della dimensione delle unità LSTM nella prima parte del modello, in modo tale da fornire una maggiore capacità di rappresentazione delle sequenze.

3. Bilanciamento delle classi tramite class weights, che ha consentito di ridurre il bias verso la classe più rappresentata e migliorare la sensibilità del modello nel riconoscere i campioni appartenenti al gruppo ASD.

In definitiva, la fase di training ha migliorato la complessità del modello, sviluppando una rete stabile e capace di apprendere strutture informative senza sfociare in overfitting marcato. Le metriche finali hanno poi confermato l'efficacia delle strategie adottate, con un buon compromesso tra accuratezza globale e capacità discriminativa sulle due classi.

—

3.7 Valutazione delle prestazioni

La valutazione delle prestazioni del modello rappresenta un passaggio fondamentale per analizzare la reale capacità predittiva e per verificare se la rete neurale sia stata in grado di generalizzare correttamente dalle sequenze di addestramento a quelle di validazione.

Il *classification report* fornisce una panoramica completa e dettagliata delle principali metriche di performance come precision, recall e F1-score.

Oltre a queste metriche, il report evidenzia anche il *support*, ossia il numero di campioni appartenenti a ciascuna classe presenti nel set di validazione. Questo valore non rappresenta una metrica di valutazione, ma fornisce un'indicazione della distribuzione dei dati e permette di interpretare al meglio la significatività delle metriche stesse.

L'insieme delle misure riportate offre quindi una visione chiara del comportamento del modello sulle due classi(ASD e neurotipici), mostrando eventuali squilibri predittivi.

I risultati ottenuti sono riportati nella Tabella 3.1

Metrica	**ASD**	**Neurotipici**	**Macro avg**	**Weighted avg**
Precision	0.88	0.95	0.92	0.92
Recall	0.94	0.90	0.92	0.92
F1-score	0.91	0.92	0.92	0.92
Support	37 564	45 133	82 697	82 697
Accuracy			0.92	

Tabella 3.1: Classification report del modello LSTM bidirezionale.

Si può facilmente osservare come il modello mantenga prestazioni equilibrate tra le due classi, con valori medi superiori al 90%. L'accuratezza complessiva

raggiunge il 92%, un risultato notevole considerando la complessità del problema e la variabilità intrinseca dei dati.

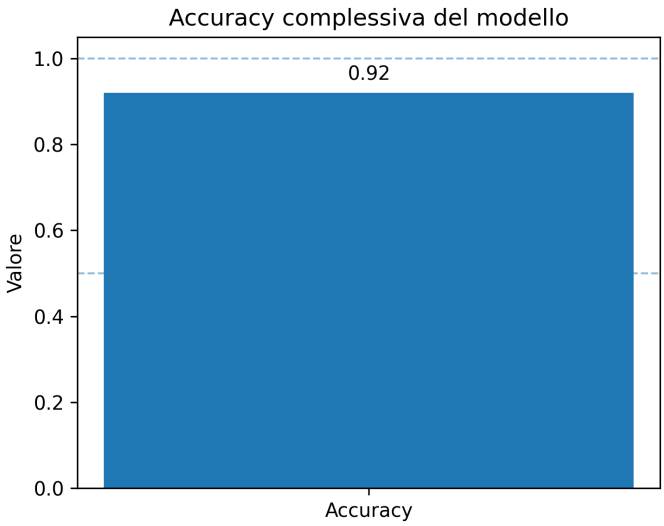


Figura 3.1: Accuratezza complessiva del modello.

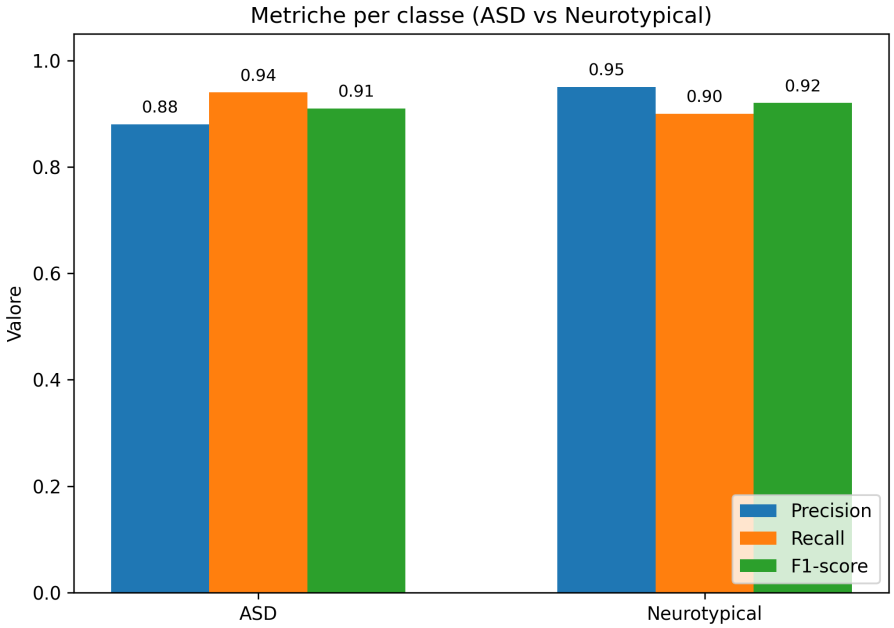


Figura 3.2: Metriche per classe (ASD vs Neurotipici): precision, recall e F1-score.

La matrice di confusione è un ulteriore strumento che mostra come le predizioni siano distribuite tra le classi reali. Le celle della diagonale principale indicano le predizioni corrette, mentre quelle fuori diagonale evidenziano gli errori di classificazione.

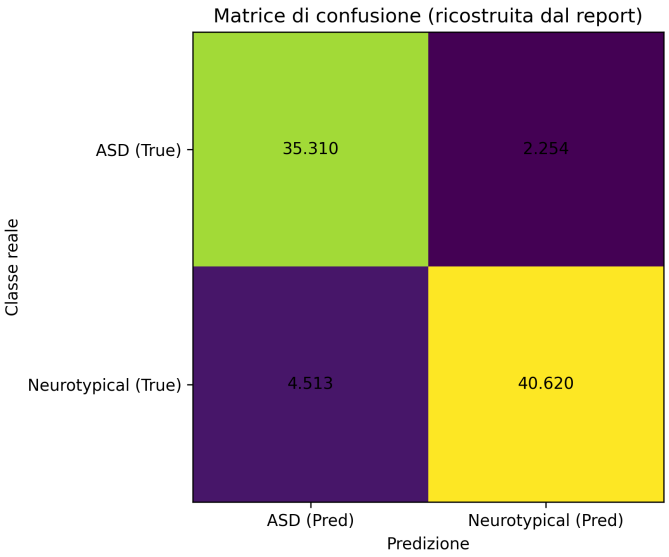


Figura 3.3: Matrice di confusione del modello (ASD vs Neurotipici).

La maggior parte dei soggetti ASD viene correttamente identificata come tale (recall alto per ASD, 0.94), mentre alcuni casi vengono classificati erroneamente come neurotipici. Viceversa, il modello riconosce i soggetti neurotipici con una precisione del 95%, anche se con un leggero calo nel recall (0.90). Sebbene il modello commetta qualche errore di sensibilità verso i soggetti neurotipici, possiamo ritenere quest'ultimo molto affidabile nel ridurre i falsi positivi per questa classe.

L'AUC ottenuto si aggira intorno a 0.96, valore che denota un'elevata capacità del modello nel distinguere correttamente tra soggetti ASD e neurotipici.

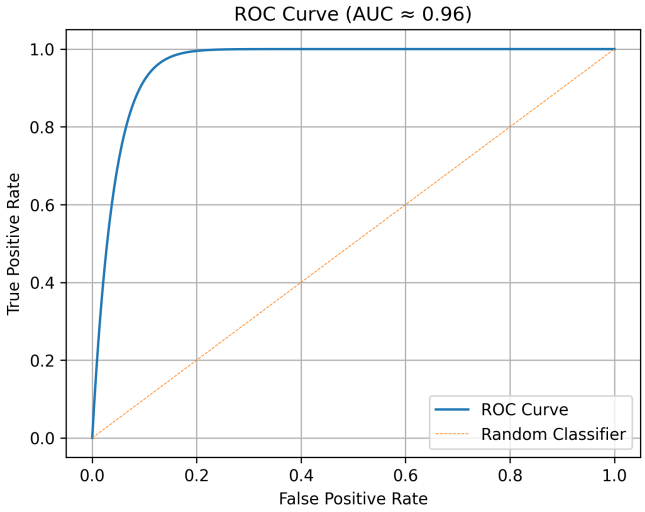


Figura 3.4: Curva ROC del modello. L'area sotto la curva (AUC) è pari a 0,96, indicando un'ottima capacità discriminante tra soggetti ASD e neurotipici. La vicinanza della curva all'angolo in alto a sinistra riflette alta sensibilità e specificità, con riduzione di falsi positivi e falsi negativi.

Una curva ROC vicina all'angolo superiore sinistro del grafico indica infatti che il modello riesce a massimizzare contemporaneamente la sensibilità e la specificità, abbassando il rischio di errori sia in termini di falsi negativi che di falsi positivi.

—

3.7.1 Discussione dei risultati

I risultati complessivi mostrano che il modello ha raggiunto prestazioni solide ed equilibrate. Analizzando i valori:

1. **Classe ASD**: il modello evidenzia un recall molto alto (0.94), segnalando che riesce ad identificare correttamente la maggior parte dei soggetti nello spettro autistico. Ciò è particolarmente importante in ambito clinico, dove la priorità è ridurre il rischio di falsi negativi (soggetti ASD non riconosciuti). La precisione, leggermente più bassa (0.88), testimonia che qualche soggetto neurotipico è stato erroneamente classificato come ASD, ma questo errore risulta accettabile in un contesto di screening, dove è preferibile sovrastimare piuttosto che sottostimare i casi positivi.

2. **Classe neurotipica**: i soggetti tipici vengono riconosciuti con un'ottima precision (0.95), il che significa che quando il modello li classifica come tali, è molto probabile che la predizione sia corretta. Il recall (0.90) risulta inferiore rispetto a quello della classe ASD, segnalando che una piccola parte dei soggetti neurotipici è stata identificata erroneamente come ASD.

In generale, il modello bilancia bene sensibilità e specificità, mostrando un comportamento leggermente più attendibile verso la classe ASD. L'accuratezza globale del 92% e l'AUC del 96% confermano che l'architettura LSTM bidirezionale adottata, unita al preprocessing e alle strategie di ottimizzazione e regolarizzazione, hanno permesso di ottenere un modello robusto e affidabile.

—

3.7.2 Confronto con il modello iniziale

Il presente lavoro di tesi è stato sviluppato a partire da un modello di Deep Learning preliminare basato su una rete neurale di tipo multi-layer perceptron (MLP) [47, 48]. Questa architettura, di natura feed-forward, era costituita da due livelli densi (128 e 64 unità con attivazione ReLU) e regolarizzazione tramite Dropout. Il modello utilizzava come input le feature tabellari statiche ottenute dai dati di eye-tracking, senza alcuna considerazione della componente temporale. Tale configurazione, quindi, aveva l'obiettivo di rappresentare un punto di partenza su cui basare i successivi sviluppi e forniva una baseline di riferimento per le prestazioni. I risultati del modello MLP sono stati nel complesso discreti. L'accuratezza complessiva ha raggiunto il valore 0.88, con metriche bilanciate tra le due classi. In particolare, per i soggetti ASD il modello ha ottenuto una precisione di 0.87, un recall di 0.86 e un F1-score di 0.87; mentre per i soggetti neurotipici i valori

sono stati rispettivamente pari a 0.88, 0.90 e 0.89. Il recall relativamente basso sulla classe ASD (0.86) mostra che una parte dei soggetti nello spettro non veniva correttamente identificata, aumentando il rischio di falsi negativi, fattore critico in ambito clinico. Di conseguenza, il modello MLP, pur mostrando una discreta capacità discriminativa, presenta limiti evidenti nella predizione.

I risultati ottenuti sono riportati nella Tabella 3.2

Metrica	**ASD**	**Neurotipici**	**Macro avg**	**Weighted avg**
Precision	0.87	0.88	0.88	0.88
Recall	0.86	0.90	0.88	0.88
F1-score	0.87	0.89	0.88	0.88
Support	37 727	44 972	82 699	82 699
Accuracy			0.88	

Tabella 3.2: Classification report del modello MLP di partenza.

Nella Tabella 3.3 viene presentato un confronto diretto tra le prestazioni dei due modelli, mettendo in evidenza i progressi in termini di accuratezza, sensibilità e capacità discriminativa complessiva.

Metrica	**MLP (modello iniziale)**	**BiLSTM (modello finale)**
Accuracy	0.88	0.92
Precision ASD	0.87	0.88
Recall ASD	0.86	0.94
F1-score ASD	0.87	0.91
Precision Neurotipici	0.88	0.95
Recall Neurotipici	0.90	0.90
F1-score Neurotipici	0.89	0.92
Macro avg (P/R/F1)	0.88 / 0.88 / 0.88	0.92 / 0.92 / 0.92
Weighted avg (P/R/F1)	0.88 / 0.88 / 0.88	0.92 / 0.92 / 0.92
AUC (ASD positivo)	0.90	0.96

Tabella 3.3: Confronto tra modello iniziale (MLP) e modello finale (BiLSTM).

Nota: P = Precision, R = Recall, F1 = F1-score.

Il confronto tra i due modelli evidenzia chiaramente i progressi ottenuti. Con l'architettura BiLSTM l'accuratezza è salita a 0,92, il recall per la classe ASD ha raggiunto 0,94 e l'AUC si è attestato a 0,96. Anche le metriche per la classe neurotipica sono migliorate notevolmente in termini di precisione (0,95) e F1-score (0,92). Rispetto al modello di partenza, la nuova architettura di rete raggiunge una maggior robustezza e un'elevata sensibilità nella rilevazione dei soggetti ASD, qualità che ne rafforzano l'utilità come strumento di supporto nello screening precoce.

—

3.8 Considerazioni finali sul modello

Il modello sviluppato in questo lavoro di tesi ha mostrato risultati incoraggianti, dimostrando come l'utilizzo di reti neurali ricorrenti bidirezionali, in particolare architetture LSTM, possa rivelarsi un approccio efficace per la classificazione di soggetti con Disturbo dello Spettro Autistico (ASD) rispetto a soggetti neurotipici. L'accuratezza ottenuta e l'analisi delle principali metriche di valutazione [49] hanno evidenziato un buon livello di affidabilità e precisione, confermando la solidità del percorso metodologico seguito.

—

3.8.1 Punti di forza

Uno degli aspetti più determinanti riguarda l'elevata accuratezza ottenuta, che testimonia la capacità del modello di differenziare correttamente tra le due classi in esame. Tale risultato non è banale se si pensa alla complessità intrinseca dei dati clinici e comportamentali, contraddistinti spesso da variabilità individuale e rumore sperimentale.

Un ulteriore punto di forza è rappresentato dall'equilibrio predittivo tra le due classi. L'uso di pesi bilanciati, infatti, ha permesso di ridurre il rischio che la rete si concentrasse sulla classe maggioritaria, garantendo prestazioni omogenee e un'equa sensibilità nei confronti di ASD e neurotipici.

A questo si aggiunge la robustezza del modello fornita tramite le tecniche di regolarizzazione (dropout, batch normalization, early stopping), che hanno limitato il rischio di overfitting, favorendo una generalizzazione più precisa sui set di validation.

—

3.8.2 Limiti

Nonostante i risultati positivi ottenuti, il lavoro presenta numerose criticità.

Innanzitutto, la dimensione ridotta del campione rappresenta un evidente ostacolo, in quanto dataset di piccole dimensioni, seppur trattati con tecniche di bilanciamento e sequenzializzazione, possono limitare la capacità del modello di cogliere la piena eterogeneità del fenomeno clinico.

Inoltre, la presenza di variabili mancanti, ad esempio alcuni punteggi relativi alla scala CARS, ha ridotto il potenziale informativo del modello, limitando la possibilità di sfruttare appieno alcuni indicatori clinici fondamentali utili per una caratterizzazione più completa e affidabile del profilo dei soggetti analizzati.

Un ulteriore limite riguarda la generalizzazione dei risultati. Il modello, infatti, è stato validato su un unico dataset; pertanto, le prestazioni osservate non possono essere automaticamente estese a popolazioni differenti, in quanto il rischio di overfitting al contesto specifico rimane concreto.

—

3.8.3 Spunti per lavori futuri

Sulla base di queste considerazioni, diversi sviluppi futuri appaiono promettenti.

In primo luogo, l'integrazione di nuovi dataset, più ampi e diversificati, costituirebbe un passo fondamentale per aumentare la robustezza e la validità del modello. Disporre di campioni provenienti da diversi centri clinici o studi longitudinali permetterebbe di validare l'approccio su popolazioni eterogenee, rendendo più affidabile la generalizzazione.

Dal punto di vista metodologico, invece, si potrebbero esplorare architetture più complesse, come i modelli ibridi CNN-LSTM, capaci di combinare l'estrazione automatica di pattern spaziali con l'analisi sequenziale.

Analogamente, l'impiego di tecniche di transfer learning potrebbe rivelarsi utile per sfruttare conoscenze già apprese da modelli addestrati su dataset più ampi, abbassando drasticamente i vincoli legati alla scarsità di dati clinici specifici.

Infine, un'estensione del modello a un approccio multimodale, idoneo a integrare informazioni eterogenee (dati comportamentali, clinici, neurofisiologici), aprirebbe la strada a una valutazione più completa e vicina alla complessità del disturbo autistico.

—

Conclusioni

Il Disturbo dello Spettro Autistico (ASD) è una condizione complessa, eterogenea e multidimensionale, caratterizzata da difficoltà nella comunicazione sociale e da pattern comportamentali atipici.

La diagnosi richiede competenze specialistiche, osservazioni cliniche e l'utilizzo di strumenti standardizzati. Tuttavia, i tempi lunghi e la complessità del processo diagnostico rendono di fondamentale importanza la ricerca di metodi complementari in grado di supportare i professionisti e anticipare l'individuazione del disturbo.

In questo ambito, l'Intelligenza Artificiale e, in particolare, gli algoritmi di Machine Learning e di Deep Learning si stanno rivelando strumenti promettenti. La loro capacità di analizzare grandi dataset e individuare pattern nascosti li rende candidati ideali per affiancare il lavoro clinico.

Il presente lavoro di tesi ha lo scopo di sviluppare e validare un modello predittivo in grado di distinguere tra soggetti con ASD e soggetti neurotipici (TD), a partire da variabili cliniche e comportamentali. Il modello definitivo, basato su un'architettura BiLSTM, è stato sviluppato come evoluzione di un modello preliminare fornito come baseline.

La prima parte del lavoro si è posta come obiettivo l'inquadramento teorico del disturbo. Sono stati analizzati i principali aspetti clinici, dalla sua definizione alle caratteristiche sintomatologiche, con particolare attenzione alle difficoltà legate alla diagnosi precoce.

È emerso come la complessità e l'eterogeneità del disturbo rendano necessario il ricorso a strumenti diagnostici multipli e come la valutazione rimanga un processo strutturato e fortemente dipendente dall'esperienza clinica.

Successivamente, è stato introdotto il tema dell'Intelligenza Artificiale, con un focus sul Machine Learning e sul Deep Learning, descrivendone le potenzialità in ambito biomedico. Sono state evidenziate le principali metriche di valutazione utilizzate per misurare un modello predittivo e la fase di preprocessing dei dati: dalla gestione dei valori mancanti e degli outlier, fino alla standardizzazione, al bilanciamento delle classi e alle tecniche di feature selection.

Questo capitolo ha posto le basi metodologiche necessarie per comprendere come dati clinici eterogenei possano essere trasformati in input idonei per modelli complessi.

Il terzo capitolo rappresenta il cuore sperimentale della tesi. Dopo aver descritto in dettaglio il dataset e le sue caratteristiche, si è passati alla fase di prepro-

cessing specifica per l'architettura LSTM, alla creazione delle sequenze temporali e alla definizione della struttura del modello.

Sono state delineate, inoltre, diverse tecniche di regolarizzazione e ottimizzazione, tra cui dropout, batch normalization, early stopping e riduzione del learning rate, con lo scopo di fornire stabilità e ridurre il rischio di overfitting.

Infine, il modello è stato validato attraverso le metriche descritte nel capitolo due.

I risultati ottenuti hanno evidenziato un'elevata accuratezza e un valore di AUC pari a circa 0.96, a testimonianza di un'ottima capacità discriminante del modello. Questi dati confermano il miglioramento rispetto al modello preliminare MLP e dimostrano che le reti neurali ricorrenti, in particolare le LSTM bidirezionali, rappresentano una tecnica promettente per l'analisi di dati clinici e comportamentali.

Tuttavia, il lavoro presenta alcuni limiti, come la dimensione del campione ridotta e la presenza di variabili mancanti, che limitano la possibilità di sfruttare in modo ottimale gli indicatori fondamentali.

In conclusione, questa tesi ha mostrato che l'Intelligenza Artificiale può rappresentare un supporto concreto alla diagnosi del Disturbo dello Spettro Autistico.

L'obiettivo non è sostituire il lavoro di medici e professionisti, ma fornire strumenti capaci di integrare e arricchire il processo decisionale, rendendo la diagnosi più tempestiva, oggettiva e personalizzata.

—

Bibliografia e Sitografia

[1] Catherine Lord, Mayada Elsabbagh, Gillian Baird, and Jeremy Veenstra-VanderWeele. Autism spectrum disorder. *The Lancet*, 392(10146):508–520, 2018.

[2] Angelica Ronald and Rosa A. Hoekstra. Autism spectrum disorders and autistic traits: A decade of new twin studies. *American Journal of Medical Genetics Part B: Neuropsychiatric Genetics*, 156(3):255–274, 2011.

[3] Ahmad Modabbernia, Eva Velthorst, and Abraham Reichenberg. Environmental risk factors for autism: an evidence-based review of systematic reviews and meta-analyses. *Molecular Autism*, 8(13):1–16, 2017.

[4] Jamileh Zeidan, Eric Fombonne, Jodie Scorah, Alaa Ibrahim, Maureen S. Durkin, Shekhar Saxena, Ayesha Yusuf, Ann M. Shih, and Mayada Elsabbagh. Global prevalence of autism: A systematic review update. *Autism Research*, 15(5):778–790, 2022.

[5] Ministero della Salute. Autismo: i dati epidemiologici in italia. `https://www.salute.gov.it/portale/temi/p2_6.jsp?lingua=italiano&id=3907&area=Malattie%20rare&menu=epidemiologia`, 2022. Accesso: 2025-08-28.

[6] American Psychiatric Association. *Diagnostic and Statistical Manual of Mental Disorders, Fifth Edition (DSM-5)*. American Psychiatric Publishing, Arlington, VA, 2013.

[7] World Health Organization. International classification of diseases, 11th revision (icd-11). `https://icd.who.int/`, 2019.

[8] Catherine Lord, Mayada Elsabbagh, Gillian Baird, and Jeremy Veenstra-Vanderweele. Autism spectrum disorder. *The Lancet*, 392(10146):508–520, 2018.

[9] Fred R. Volkmar and James C. McPartland. From kanner to dsm-5: autism as an evolving diagnostic concept. *Annual Review of Clinical Psychology*, 10:193–212, 2014.

[10] Ministero della Salute. Disturbi dello spettro autistico. `https://www.salute.gov.it/portale/autismo/`, 2021.

[11] M. J. Maenner, K. A. Shaw, J. Baio, et al. Prevalence of autism spectrum disorder among children aged 8 years — united states, 2016. *MMWR Surveillance Summaries*, 69(4):1–12, 2020.

[12] Rachel Loomes, Laura Hull, and William P. L. Mandy. What is the male-to-female ratio in autism spectrum disorder? a systematic review and meta-analysis. *Journal of the American Academy of Child & Adolescent Psychiatry*, 56(6):466–474, 2017.

[13] Leo Kanner. Autistic disturbances of affective contact. *Nervous Child*, 2:217–250, 1943.

[14] American Psychiatric Association. *Diagnostic and Statistical Manual of Mental Disorders, 5th Edition, Text Revision (DSM-5-TR)*. APA Publishing, Washington, DC, 2022.

[15] Editors of The Lancet. Retraction—"ileal-lymphoid-nodular hyperplasia, non-specific colitis, and pervasive developmental disorder in children". *The Lancet*, 375(9713):445, 2010.

[16] Fred R. Volkmar and Brian Reichow. Autism in dsm-5: progress and challenges. *Molecular Autism*, 4(13):1–6, 2013.

[17] Catherine Lord, Michael Rutter, Pamela DiLavore, Susan Risi, Katherine Gotham, and Somer Bishop. *Autism Diagnostic Observation Schedule, Second Edition (ADOS-2)*. Western Psychological Services, 2012.

[18] Michael Rutter, Ann Le Couteur, and Catherine Lord. *Autism Diagnostic Interview-Revised (ADI-R)*. Western Psychological Services, 2003.

[19] Eric Schopler, Robert J. Reichler, and Barbara R. Renner. *The Childhood Autism Rating Scale (CARS)*. Western Psychological Services, 1988.

[20] Stuart Russell and Peter Norvig. *Artificial Intelligence: A Modern Approach*. Pearson, 3rd edition, 2016.

[21] Tom M. Mitchell. *Machine Learning*. McGraw-Hill, 1997.

[22] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *Nature*, 521:436–444, 2015.

[23] Andre Esteva, Alexandre Robicquet, Bharath Ramsundar, Volodymyr Kuleshov, Mark DePristo, Katherine Chou, Claire Cui, Greg Corrado, Sebastian Thrun, and Jeff Dean. A guide to deep learning in healthcare. *Nature medicine*, 25(1):24–29, 2019.

[24] Geert Litjens, Thijs Kooi, Babak Ehteshami Bejnordi, Arnaud Arindra Adiyoso Setio, Francesco Ciompi, Mohsen Ghafoorian, Jeroen AWM van der Laak, Bram van Ginneken, and Clara I Sánchez. A survey on deep learning in medical image analysis. *Medical image analysis*, 42:60–88, 2017.

[25] Scott M Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 4765–4774, 2017.

[26] Jiawei Han, Jian Pei, and Micheline Kamber. *Data Mining: Concepts and Techniques*. Elsevier, 2011.

[27] Diario di un Analista. Guida alla gestione dei dati mancanti nella data science, 2021. Accesso: 16 settembre 2025.

[28] GeeksforGeeks. Data duplication removal from dataset using python, 2021. Accessed: 2025-09-16.

[29] Scikit-learn developers. Preprocessing data — scikit-learn documentation, 2025. Accessed: 2025-09-17.

[30] Scikit-learn developers. Standardization of datasets — scikit-learn documentation, 2025. Accessed: 2025-09-17.

[31] Guillaume Lemaître, Fernando Nogueira, and Christos K. Aridas. Imbalanced-learn: A python toolbox to tackle the curse of imbalanced datasets in machine learning, 2017. Accessed: 2025-09-17.

[32] Isabelle Guyon and André Elisseeff. An introduction to variable and feature selection. *Journal of Machine Learning Research*, 3:1157–1182, 2003.

[33] Scikit-learn. Feature selection. `https://scikit-learn.org/stable/modules/feature_selection.html`, 2025. Ultimo accesso: settembre 2025.

[34] Scikit-learn. Feature selection: Embedded methods. `https://scikit-learn.org/stable/modules/feature_selection.html`, 2025. Ultimo accesso: settembre 2025.

[35] Federica Cilia, Romualdo Carette, Mahmoud Elbattah, Jean-Luc Guérin, and Gilles Dequen. Eye-tracking dataset to support autism spectrum disorder research. `https://www.kaggle.com/datasets/imtkaggleteam/eye-tracking-autism`, 2022. License: CC BY-SA 4.0.

[36] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997.

[37] Mike Schuster and Kuldip K. Paliwal. Bidirectional recurrent neural networks. *IEEE Transactions on Signal Processing*, 45(11):2673–2681, 1997.

[38] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural computation*, 9(8):1735–1780, 1997.

[39] Vinod Nair and Geoffrey E. Hinton. Rectified linear units improve restricted boltzmann machines. pages 807–814, 2010.

[40] Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, pages 448–456, 2015.

[41] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(1):1929–1958, 2014.

[42] John S. Bridle. Probabilistic interpretation of feedforward classification network outputs, with relationships to statistical pattern recognition. In *Neurocomputing: Algorithms, Architectures and Applications*, pages 227–236. Springer, 1990.

[43] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.

[44] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015.

[45] Martín Abadi, Ashish Agarwal, Paul Barham, et al. TensorFlow: Large-scale machine learning on heterogeneous systems, 2015. Software available from tensorflow.org.

[46] Lutz Prechelt. Early stopping — but when? In Genevieve B. Orr and Klaus-Robert Müller, editors, *Neural Networks: Tricks of the Trade*, volume 1524 of *Lecture Notes in Computer Science*, pages 55–69. Springer, 1998.

[47] Frank Rosenblatt. The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, 65(6):386–408, 1958.

[48] David E. Rumelhart, Geoffrey E. Hinton, and Ronald J. Williams. Learning representations by back-propagating errors. *Nature*, 323(6088):533–536, 1986.

[49] David M. W. Powers. Evaluation: From precision, recall and f-measure to roc, informedness, markedness and correlation. *Journal of Machine Learning Technologies*, 2(1):37–63, 2011.

Ringraziamenti